

### Análise de amostras particionadas

A abordagem de validação mais direta é uma comparação entre amostras particionadas ou multi-amostras, na qual a amostra original é dividida ou uma nova amostra é coletada. Em qualquer caso, o pesquisador deve então encontrar um meio para comparar os resultados. Muitas vezes, a comparação entre resultados é feita visualmente ou com uma simples correlação de coordenadas. Alguns programas de comparação estão disponíveis, como FMATCH [24], mas o pesquisador ainda deve determinar quantas das disparidades decorrem das diferenças em percepções de objetos, em dimensões ou ambas.

### Comparação de soluções decomposicionais versus composicionais

Um outro método é obter uma convergência de resultados MDS pela aplicação de técnicas composicionais e decomposicionais na mesma amostra. Os métodos decomposicionais poderiam ser aplicados em primeiro lugar, juntamente com a interpretação das dimensões para identificar atributos-chave. Então, um ou mais métodos composicionais, particularmente a análise de correspondência, poderiam ser aplicados para confirmar os resultados. O pesquisador deve perceber que isso não é uma verdadeira validação dos resultados em termos de generalidade, mas confirma a interpretação da dimensão. Deste ponto de vista, esforços de validação com outras amostras e outros objetos poderiam ser empreendidos para demonstrar a generalidade para outras amostras.

### Resumo

A falta de métodos internos para comparação direta entre soluções, juntamente com a difícil tarefa de se comparar soluções perceptuais, resulta em vários métodos *ad hoc* para validação, sendo que nenhum deles é completamente satisfatório. Pesquisadores são encorajados a aplicarem ambas as técnicas de validação sempre que possível, para obterem o máximo de suporte para a generalidade de qualquer solução MDS.

## VISÃO GERAL DO ESCALONAMENTO MULTIDIMENSIONAL

Escalonamento multidimensional representa um método distinto para a análise multivariada quando comparado com outros métodos neste texto. Enquanto outras técnicas estão focadas na especificação precisa de atributos abrangendo variáveis independentes e/ou dependentes, o escalonamento multidimensional segue um tratamento totalmente diferente. Ele reúne apenas medidas globais ou holísticas de similaridade ou preferência e, em seguida, infere empiricamente as dimensões (caráter e número) que refletem a melhor explicação das respostas de um indivíduo, seja em separado ou coletivamente. Nesta técnica,

### REGRAS PRÁTICAS 9-3

#### Obtenção e validação de uma solução MDS

- Medidas de desajuste (valores menores são melhores) representam um ajuste de solução MDS
- Pesquisadores podem identificar uma solução MDS degenerada que é geralmente problemática procurando por:
  - Um padrão circular de objetos que sugere que todos eles são igualmente semelhantes, ou
  - Uma solução multiagregada na qual objetos são reunidos em dois extremos de um único contínuo
- O número apropriado de dimensões para um mapa perceptual é baseado em:
  - Um julgamento subjetivo se a solução com uma dada dimensionalidade é razoável
  - Uso de um gráfico *scree* para identificar onde acontece uma substancial melhora de ajuste
  - Uso de  $R^2$  como um índice de ajuste; medidas de 0,6 ou mais são consideradas aceitáveis
- Análise externa, como a executada por PREFMAP, é considerada preferível na geração de pontos ideais, em comparação com análise interna
- O método de validação mais direto é uma abordagem via amostras particionadas
  - Múltiplas soluções são geradas particionando a amostra original ou coletando novos dados
  - Validade é indicada quando as múltiplas soluções conferem

ca, a variável estatística usada em muitos outros métodos se transforma nas dimensões perceptuais inferidas a partir da análise. Como tal, o pesquisador não tem que se preocupar com questões como erro de especificação, multicolinearidade ou características estatísticas das variáveis. O desafio para o pesquisador, porém, é a interpretação da variável estatística; sem uma interpretação válida, os objetivos principais de MDS ficam comprometidos.

A aplicação de MDS é adequada quando o objetivo é mais orientado para a compreensão das preferências ou percepções gerais, em vez de perspectivas detalhadas que envolvam atributos individuais. No entanto, uma técnica combina a especificidade da análise de atributos dentro de soluções do tipo MDS. Tal método, análise de correspondência, é discutido na seção a seguir, onde as semelhanças e diferenças em relação a técnicas tradicionais de MDS são destacadas.

## ANÁLISE DE CORRESPONDÊNCIA

Até este ponto, discutimos as abordagens decomposicionais tradicionais para MDS; mas e quanto às técnicas composicionais? No passado, as abordagens composicionais basearam-se em técnicas multivariadas tradicionais, como

as análises discriminante e fatorial. Mas desenvolvimentos recentes combinam aspectos de ambos os métodos e o MDS para formar novas e poderosas ferramentas para mapeamento perceptual.

### Características diferenciadas

**Análise de correspondência (CA)** é uma técnica de interdependência que tem se tornado cada vez mais popular para redução dimensional e mapeamento perceptual [1, 2, 11, 13, 19]. Também é conhecida como escalonamento ou escore ótimo, média recíproca ou análise de homogeneidade. Quando comparada com as técnicas MDS descritas na parte anterior deste capítulo, a análise de correspondência apresenta três características que a distinguem:

1. É uma técnica composicional, e não decomposicional, porque o mapa perceptual é baseado na associação entre objetos e um conjunto de características descritivas ou atributos especificados pelo pesquisador.
2. Sua aplicação mais direta é na retratação da correspondência de categorias de variáveis, particularmente aquelas medidas em escalas nominais. Tal correspondência é, desse modo, a base para o desenvolvimento de mapas perceptuais.
3. Os únicos benefícios de CA residem em sua habilidade para representar linhas e colunas, por exemplo, marcas e atributos, em um espaço conjunto.

### Diferenças de outras técnicas multivariadas

Entre as técnicas composicionais, a análise fatorial é a mais semelhante pela definição de dimensões compostas (fatores) das variáveis (p.ex., atributos) e pela representação gráfica de objetos (p. ex., produtos) em seus escores sobre cada dimensão. Na análise discriminante, produtos podem ser distinguidos por seus perfis em um conjunto de variáveis e graficamente representados em um espaço dimensional. A análise de correspondência se estende além dessas duas técnicas composicionais:

- CA pode ser usada com dados nominais (p.ex., contagens de frequência de preferência para objetos em um conjunto de atributos) em vez de avaliações métricas de cada objeto sobre cada objeto\*. Tal capacidade permite que CA seja usada em muitas situações nas quais as técnicas multivariadas mais tradicionais são inadequadas.

\* N. de R. T.: A frase correta seria “de cada objeto sobre cada atributo”.

- CA cria mapas perceptuais em um único passo, onde variáveis e objetos são simultaneamente representados no mapa perceptual com base diretamente na associação de variáveis e objetos. As relações entre objetos e variáveis são a meta explícita da CA.

Primeiro examinamos um exemplo simples da CA para ter uma noção de seus princípios básicos. Em seguida, discutimos cada um dos seis estágios do processo de tomada de decisões introduzido no Capítulo 1. A ênfase está nos elementos únicos da CA quando comparada com os métodos decomposicionais de MDS discutidos anteriormente.

### Um exemplo simples de CA

Examinemos uma situação simples como uma introdução à CA. Em sua forma mais básica, a CA examina as relações entre categorias de dados nominais em uma **tabela de contingência**, a tabulação cruzada de duas variáveis categóricas (não-métricas). Talvez a forma mais comum de tabela de contingência seja a tabulação cruzada de objetos e atributos (p. ex., os atributos mais distintos para cada produto ou vendas por categoria demográfica). A CA pode ser aplicada a qualquer tabela de contingência e retratar um mapa perceptual relacionando as categorias de cada variável não-métrica em um único mapa.

Usemos um exemplo simples de vendas de produtos ao longo de uma única variável demográfica (idade). Os dados em tabulação cruzada (ver Tabela 9-2) retratam as vendas para os produtos A, B e C distribuídas em três categorias de idade (jovens adultos, que estão entre 18 e 35 anos; meia-idade, entre 36 e 55 anos; e idosos, a partir de 56).

### Utilização de dados de tabulação cruzada

O que podemos aprender a partir dos dados de tabulação cruzada? Primeiro, podemos olhar os totais das colunas e linhas para identificar a ordenação das categorias (de maiores para menores). Mas mais importante, podemos ver os tamanhos relativos de cada célula da tabela de contingência refletindo a quantia de cada variável para cada objeto. A comparação de células pode identificar padrões que refletem associações entre certos objetos e atributos.

**TABELA 9-2** Dados de tabulação cruzada detalhando vendas de produtos por categoria etária

Categoria etária	Vendas			
	A	B	C	Total
Jovens adultos (18-35 anos)	20	20	20	60
Meia-idade (36-55 anos)	40	10	40	90
Indivíduos idosos (56 anos ou mais)	20	10	40	70
Total	80	40	100	220

Vendo a Tabela 9-2, percebemos que as vendas variam bastante com os produtos (o produto C tem as mais altas vendas totais, e o produto B, as mais baixas) e com os grupos etários (meia-idade compra mais unidades, e jovens adultos compram menos). Mas queremos identificar algum padrão para as vendas, de modo que possamos estabelecer que os jovens comprem mais do produto X ou os idosos comprem mais do produto Z.

Para identificarmos padrões distintos, precisamos de mais dois elementos que ajudem a refletir a distinção de cada célula (frequência) relativa a outras células.

**Padronização de contagens de frequência.** O primeiro é uma medida padronizada das contagens de células que considera simultaneamente as diferenças em totais de linhas e colunas. Podemos diretamente comparar as células quando todos os totais de linhas e colunas são iguais, o que raramente é o caso. Em vez disso, os totais de linhas e colunas são geralmente desiguais. Neste caso, precisamos de uma medida que compare o valor de cada célula com um valor esperado que reflita os totais específicos de linha e coluna daquela célula.

Em nosso exemplo de vendas, esperamos que cada grupo etário do produto C tenha os maiores totais se todas as demais coisas forem iguais, pois o produto C tem as maiores vendas gerais. Analogamente, como os dados incluem mais adultos de meia-idade do que de qualquer outra categoria, esperamos assim que a célula para vendas do produto C entre adultos de meia idade seja a maior. Ainda que o valor de 40 seja o maior, diversas outras células também apresentam o mesmo valor. Tais valores significam que aquela célula é tão alta quanto o esperado, e se não, qual entre as demais células é realmente a maior? Assim, precisamos de uma medida que mostre o quão acima ou abaixo uma célula específica está quando comparada com algumas medidas esperadas de vendas.

**Representação de cada célula.** Mesmo com uma medida padronizada, ainda precisamos de um método para retratar cada célula em um mapa perceptual. Aqui, células com valores padronizados maiores que o esperado devem fazer com que combinações de objetos/variáveis fiquem localizadas mais próximas, ao passo que valores padronizados muito menores que o esperado podem fazer com que tais combinações fiquem mais separadas. A tarefa é desenvolver um mapa perceptual que melhor retrate todas as associações representadas pelas células da tabela de contingência.

Em nosso exemplo de produto, examinemos as três células com valores de 40. Como descrevemos, a célula de

Meia-idade/Produto C deve ter um valor alto por ser uma combinação das maiores categorias de linha e coluna. Mas e quanto às vendas de 40 unidades da categoria do Produto A na categoria Meia-idade? O Produto A tem vendas gerais menores que o Produto C, e assim esse resultado provavelmente mostra uma associação de algum modo maior entre essas duas categorias. Então temos as vendas de 40 unidades entre indivíduos idosos e o Produto C. Aqui, podemos dizer que esta célula tem associação maior do que nossa primeira célula (Produto C/Meia-idade), pois ambas são para o Produto C. Como esses resultados se comparam com vendas do Produto A no grupo de Meia-idade? Não importa quais sejam os valores padronizados, queremos ter as categorias de Indivíduos Idosos/Produto C e Meia-idade/Produto A representadas mais proximamente entre si em um mapa perceptual do que Meia-idade/Produto C.

Em uma representação gráfica, grupos etários estariam localizados mais próximos a produtos com os quais são altamente associados e mais afastados daqueles com menores associações. Analogamente, queremos ser capazes de ver qualquer produto e perceber suas associações com vários grupos etários.

Para este fim, discutimos nas próximas seções como CA calcula uma medida padronizada de associação com base nas contagens de células da contingência, e então o processo pelo qual essas associações são convertidas em um mapa perceptual.

### ***Cálculo de uma medida de associação ou similaridade***

A análise de correspondência usa um dos conceitos estatísticos mais básicos, o qui-quadrado, para padronizar os valores de frequência da tabela de contingência e formar a base para associação ou similaridade. Qui-quadrado é uma medida padronizada de frequências reais de células comparadas com frequências esperadas de células. Em nossos dados tabulados, cada célula contém os valores para uma combinação específica de linha/coluna. O procedimento qui-quadrado prossegue então em quatro passos para calcular um valor qui-quadrado para cada célula e então transformá-lo em uma medida de associação:

**Passo 1: Cálculo das vendas esperadas.** O primeiro passo é calcular o valor esperado para uma célula como se não existisse qualquer associação. As vendas esperadas são definidas como a probabilidade conjunta da combinação da coluna com a linha. Isso é calculado como a probabilidade marginal para a coluna (total da coluna / total geral) vezes a probabilidade marginal para a linha (total da linha / total geral). Esse valor é então multiplicado pelo total geral. Para qualquer célula, o valor esperado pode ser simplificado pela seguinte equação:

$$\text{Contagem esperada da célula} = \frac{\text{Total da coluna da célula} \times \text{Total da linha da célula}}{\text{Total geral}}$$

Este cálculo representa a frequência esperada da célula dadas as proporções para os totais de linha e coluna.

As frequências esperadas fornecem uma base para comparação com as frequências reais e viabilizam o cálculo de uma medida padronizada de associação usada na construção do mapa perceptual.

Em nosso exemplo simples, as vendas esperadas para os Jovens adultos que compram o Produto A são de 21,82 unidades, como mostrado no seguinte cálculo:

$$\text{Vendas esperadas}_{\text{Jovens adultos, Produto A}} = \frac{60 \times 80}{220} = 21,82$$

Esse cálculo é feito para cada célula, com os resultados exibidos na Tabela 9-3.

**Passo 2: Diferença entre frequências de células esperadas e reais.** O próximo passo é calcular a diferença entre as frequências esperadas e as reais da seguinte maneira:

$$\text{Diferença} = \text{Frequência esperada} - \text{Frequência real.}$$

A magnitude de diferença denota a força de associação e o sinal (positivo para associação menor que o esperado, e negativo para uma associação maior que o

**TABELA 9-3** Cálculo de valores qui-quadrado de similaridade para dados de tabulação cruzada

Categoria etária	Vendas de produto			
	A	B	C	Total
<b>Jovens</b>				
Vendas	20	20	20	60
Percentual da coluna	25%	50%	20%	27%
Percentual da linha	33%	33%	33%	100%
Vendas esperadas <sup>a</sup>	21,82	10,91	27,27	60
Diferença <sup>b</sup>	1,82	-9,09	7,27	-
Valor qui-quadrado <sup>c</sup>	0,15	7,58	1,94	9,67
<b>Meia-idade</b>				
Vendas	40	10	40	90
Percentual da coluna	50%	25%	40%	41%
Percentual da linha	44%	11%	44%	100%
Vendas esperadas	32,73	16,36	40,91	90
Diferença	-7,27	6,36	0,91	-
Valor qui-quadrado	1,62	2,47	0,02	4,11
<b>Idosos</b>				
Vendas	20	10	40	70
Percentual da coluna	25%	25%	40%	32%
Percentual da linha	29%	14%	57%	100%
Vendas esperadas	25,45	12,73	31,82	70
Diferença	5,45	2,73	-8,18	-
Valor qui-quadrado	1,17	0,58	2,10	3,85
<b>Total</b>				
Vendas	80	40	100	220
Percentual da coluna	100%	100%	100%	100%
Percentual da linha	36%	18%	46%	100%
Vendas esperadas	80	40	100	220
Diferença	-	-	-	-
Valor qui-quadrado	2,94	10,63	4,06	17,63

<sup>a</sup>Vendas esperadas = (Total da linha × Total da coluna) / Total geral  
Exemplo: Célula<sub>Jovens adultos, Produto A</sub> = (60 × 80) / 220 = 21,82

<sup>b</sup>Diferença = Vendas esperadas - Vendas reais  
Exemplo: Célula<sub>Jovens adultos, Produto A</sub> = 21,82 - 20,00 = 1,82

<sup>c</sup>Valor qui-quadrado =  $\frac{\text{Diferença}^2}{\text{Vendas esperadas}}$

Exemplo: Célula<sub>Jovens adultos, Produto A</sub> = 1,82<sup>2</sup> / 21,82 = 0,15



esperado) representado neste valor. É importante observar que o sinal, na verdade, é invertido quanto ao tipo de associação – um sinal negativo significa uma associação positiva (frequências reais excederam as esperadas) e vice-versa.

Novamente, em nosso exemplo da célula para Jovens que compram o Produto A, a diferença é 1,82 (21,82 – 20,00). A diferença positiva indica que as vendas reais são menores do que o esperado para esta combinação de grupo etário com produto, o que significa menos vendas do que o esperado (uma associação negativa). Células nas quais acontecem diferenças negativas indicam associações positivas (a célula realmente comprou mais do que o esperado). As diferenças para cada célula também são exibidas na Tabela 9-3.

**Passo 3: Cálculo do valor qui-quadrado.** O próximo passo é padronizar as diferenças ao longo das células de forma que comparações possam ser facilmente realizadas. A padronização é exigida porque seria muito mais fácil as diferenças ocorrerem se a frequência da célula fosse muito alta comparada com uma célula com apenas poucas vendas. Portanto, padronizamos as diferenças para formar um **valor qui-quadrado** dividindo cada diferença ao quadrado pelo valor de vendas esperado. Assim, o valor qui-quadrado para uma célula é calculado como:

$$\text{Valor qui-quadrado} = \frac{\text{Diferença}^2}{(\chi^2) \text{ de uma célula} \quad \text{Frequência esperada da célula}}$$

Para a célula de nosso exemplo, o valor qui-quadrado seria:

$$\text{Valor qui-quadrado } (\chi^2)_{\text{Jovens adultos, Produto A}} = \frac{(1,82)^2}{21,82} = 0,15$$

Os valores calculados para as outras células também são mostrados na Tabela 9-3.

**Passo 4: Criação de uma medida de associação.** O passo final é converter o valor do qui-quadrado para uma medida de similaridade. O qui-quadrado denota o grau ou quantia de similaridade ou associação, mas o processo de calcular o qui-quadrado (elevando a diferença ao quadrado) remove a direção da similaridade. Para restaurar tal direção, usamos o sinal da diferença original. Para tornar a medida de similaridade mais intuitiva (ou seja, valores positivos são associação maior e valores negativos são associação menor) também invertemos o sinal da diferença original. O resultado é uma medida que atua simplesmente como as medidas de similaridade usadas em exemplos anteriores. Valores negativos indicam menor associação (similaridade) e valores positivos apontam para maior associação.

Em nosso exemplo, o valor qui-quadrado para Jovens adultos que compram o Produto A de 0,15 seria declarado como um valor de similaridade de –0,15, pois a diferença (1,82) foi positiva. Este sinal negativo é necessário porque o cálculo de qui-quadrado eleva as diferenças ao quadrado, o que elimina sinais negativos. Os valores qui-quadrado para cada célula são também exibidos na Tabela 9-3.

As células com grandes valores positivos de similaridade (indicativos de uma associação positiva) são Jovens adultos/Produto B (17,58)\*, Meia-idade/Produto A (11,62)\* e Idosos/Produto C (12,10)\*\*\*. Cada um desses pares de categorias deve estar próximo um do outro em um mapa perceptual. Células com grandes valores negativos de similaridade (o que significa que as vendas esperadas superaram as vendas reais, ou seja, uma associação negativa) foram Jovens adultos/Produto C (–1,94), Meia-idade/Produto B (–2,47) e Idosos/Produto A (–1,17). Se possível, essas categorias devem estar bem distantes no mapa.

### Criação do mapa perceptual

Os valores de similaridades (qui-quadrados com sinal) fornecem uma medida padronizada de associação, muito parecida com os julgamentos de similaridades usados anteriormente nos métodos MDS. Com essas medidas de associação/similaridade, a CA cria um mapa perceptual usando a medida padronizada para estimar dimensões ortogonais sobre as quais as categorias podem ser colocadas para explicar melhor a intensidade de associação representada pelas distâncias qui-quadrado.

Como fizemos no exemplo do MDS, consideramos primeiro uma solução unidimensional, e então expandimos para duas dimensões e continuamos até que alcancemos o número máximo de dimensões. O máximo é um a menos do que o menor dentre os números de linhas ou colunas.

Em nosso exemplo, podemos ter apenas duas dimensões (menor dos números de linhas ou colunas menos um, ou 3 – 1 = 2). O mapa perceptual bidimensional é mostrado na Figura 9-11. Correspondendo ao nosso exame das medidas de similaridade, o grupo etário de Jovens Adultos está mais próximo do Produto B, a Meia-idade está mais próxima do Produto A, e os Idosos estão mais próximos do Produto C. De modo semelhante, as associações negativas também estão representadas nas posições de produtos e grupos etários. O pesquisador pode examinar o mapa perceptual para entender as preferências por produtos entre grupos etários com base em seus padrões de vendas. Entretanto, assim como em MDS, não sabemos por que os padrões de vendas existem, porém apenas como identificá-los.

\* N. de R. T.: O número correto é 7,58.

\*\* N. de R. T.: O número correto é 1,62.

\*\*\* N. de R. T.: O número correto é 2,10.



FIGURA 9-11 Mapa perceptual da análise de correspondência.

### Resumo

Análise de correspondência é um método híbrido de escalonamento multidimensional no sentido de que utiliza dados não-métricos cruzados para criar mapas perceptuais que podem posicionar as categorias de todas as variáveis em um único mapa. Fazendo isso, ela estende a análise MDS para todo um domínio de questões de pesquisa previamente não tratáveis pelos métodos MDS tradicionais.

### Uma estrutura de decisão para análise de correspondência

A análise de correspondência e as questões associadas com uma análise bem sucedida podem ser vistas pelo meio do processo de construção de modelo introduzido no Capítulo 1. Nas seções a seguir, examinamos as questões únicas associadas com análise de correspondência em comparação com métodos MDS ao longo de seis estágios do processo decisório.

#### Estágio 1: Objetivos da CA

Os pesquisadores são constantemente confrontados com a necessidade de quantificar os dados qualitativos encontrados em variáveis nominais. A CA difere de outras técnicas MDS em sua habilidade de acomodar tanto dados não-métricos quanto relações não-lineares. Ela faz redução dimensional semelhante a escalonamento multidimen-

sional e um tipo de mapeamento perceptual no qual as categorias são representadas no espaço multidimensional. A proximidade indica o nível de associação entre as categorias linha ou coluna. A CA pode satisfazer qualquer um dos dois objetivos básicos:

1. *Associação entre somente categorias de linha ou de coluna.* A CA pode ser usada para examinar a associação entre as categorias de apenas uma linha ou coluna. Um uso comum é o exame das categorias de uma escala, como a escala Likert (cinco categorias que variam de “concordo plenamente” a “discordo plenamente”) ou outras escalas qualitativas (p.ex., excelente, bom, regular, ruim). As categorias podem ser comparadas para ver se duas podem ser combinadas (isto é, elas estão muito próximas no mapa) ou se fornecem discriminação (ou seja, estão localizadas separadamente no espaço perceptual).
2. *Associação entre categorias de linha e coluna.* Nesta aplicação, o interesse repousa na representação da associação entre categorias das linhas e colunas, como nosso exemplo de vendas de produto por faixa etária. Esse uso é mais semelhante ao exemplo anterior de MDS e tem impulsionado a CA a um uso mais amplo em diversas áreas de pesquisa.

O pesquisador deve determinar os objetivos específicos da análise, porque certas decisões são baseadas em qual tipo de objetivo é escolhido. A CA fornece uma representação multivariada de interdependência para dados não-métricos que não é possível com outros métodos. Com uma técnica composicional, o pesquisador deve garantir que todas as variáveis relevantes adequadas à

questão de pesquisa tenham sido incluídas. Isso está em contraste com os procedimentos decomposicionais MDS descritos anteriormente, os quais exigem apenas a medida geral de similaridade.

## Estágio 2: Projeto de pesquisa de CA

A análise de correspondência exige apenas uma matriz retangular\* de dados (tabulação cruzada) de entradas não-negativas. O tipo mais comum de matriz de entrada é uma tabela de contingência com categorias específicas definindo as linhas e colunas. Ao se criar a tabela, surgem diversas questões, relativas à natureza das variáveis e categorias compreendendo linhas e colunas:

1. As linhas e colunas não têm significados pré-definidos (ou seja, os atributos não têm que ser sempre linhas e assim por diante), mas, em vez disso, representam as respostas a uma ou mais variáveis categóricas. As categorias nas linhas e colunas, porém, devem ter um significado específico para fins de interpretação.
2. As categorias para uma linha ou coluna não precisam ser uma só variável, mas podem representar qualquer conjunto de relações. Um primeiro exemplo é o método “escolha qualquer um” [14, 15], no qual é dado aos respondentes um conjunto de objetos e características. Os respondentes então indicam quais objetos, se houver algum, são descritos pelas características. O respondente pode escolher qualquer número de objetos para cada característica, e a tabela de tabulação cruzada é o número total de vezes em que cada objeto foi descrito por cada característica.
3. A tabulação cruzada pode ocorrer para mais de duas variáveis em uma forma matricial multivariada. Em tais casos, a **análise de correspondência múltipla** é empregada. Em um procedimento muito semelhante à análise bivariada, as variáveis adicionais são ajustadas de forma que todas as categorias são colocadas no mesmo espaço multidimensional.

A natureza generalizada dos tipos de relações que podem ser retratadas na tabela de contingência torna a CA uma técnica amplamente aplicável. Seu uso crescente nos últimos anos é um resultado direto do contínuo desenvolvimento de abordagens que usam este formato para analisar novos tipos de relações.

## Estágio 3: Suposições em CA

A análise de correspondência compartilha com as técnicas mais tradicionais de MDS uma relativa liberdade de pressupostos. O uso de dados estritamente não-métricos em sua forma mais simples (dados tabulados cruzados) representa as relações lineares e não-lineares igualmente bem. A falta de suposições, porém, não deve fazer com que o pesquisador negligencie os esforços para garantir a comparabilidade de objetos e, como essa é uma técnica composicional, a completude dos atributos usados.

\* N. de R. T.: Seria mais adequada a expressão “de dupla entrada”, tendo em vista que tal matriz pode também ser quadrada, quando linhas e colunas apresentam o mesmo número de categorias.

## Estágio 4: Determinação dos resultados da CA e avaliação do ajuste geral

Com uma tabela de dados cruzados, as frequências para qualquer combinação de categorias de linhas-colunas são relacionadas com outras combinações com base nas frequências marginais. Como descrito em nosso exemplo anterior, a análise de correspondência usa essa relação básica em três passos para criar um mapa perceptual:

1. Calcula uma expectativa condicional (a frequência esperada de célula) que representa a similaridade ou associação entre categorias de linha e coluna.
2. Uma vez obtidas, computam-se as diferenças entre as frequências reais e esperadas e converte-se as mesmas a uma medida padronizada (qui-quadrado). Usando-se esses resultados como uma métrica de distâncias, torna-se os mesmos comparáveis com as matrizes de entrada usadas nas abordagens MDS já discutidas.
3. Através de um processo muito parecido com o escalonamento multidimensional, cria-se uma série de soluções dimensionais (unidimensional, bidimensional etc.) sempre que possível. As dimensões relacionam simultaneamente as linhas e colunas em um único gráfico conjunto. O resultado é uma representação de categorias de linhas e/ou colunas (p.ex., marcas e atributos) no mesmo gráfico.

### Determinação do impacto de células individuais

Deve ser observado que os dois termos específicos, desenvolvidos em análise de correspondência, descrevem as propriedades dos valores de frequência e sua contribuição relativa à análise.

- O primeiro termo é **massa**, que é primeiramente definido para qualquer entrada individual na tabulação cruzada como o percentual do total representado por aquela entrada. É calculado como o valor de qualquer entrada dividido por  $N$  (o total para a tabela, que é a soma das linhas ou colunas). Assim, a soma de todas as entradas da tabela (células) é igual a 1,0. Também podemos calcular a massa de qualquer categoria de linha ou coluna, somando ao longo de todas as entradas. Tal resultado representa a contribuição de qualquer categoria de linha ou coluna para a massa total.
- A segunda medida é **inércia**, que é definida como o qui-quadrado total dividido por  $N$  (o total das contagens de frequência). Deste modo temos uma medida relativa de qui-quadrado que pode ser relacionada com qualquer contagem de frequência.

Com essas semelhanças com MDS surge um conjunto parecido de problemas, centrados em duas questões fundamentais na avaliação de ajuste geral: avaliação da importância relativa das dimensões, e então a identificação do número apropriado de dimensões. Cada um desses aspectos é discutido na próxima seção.

### Avaliação do número de dimensões

Autovalores, também conhecidos como valores singulares, são obtidos para cada dimensão e indicam a contribuição relativa de cada dimensão na explicação da variância

nas categorias. Semelhante à análise fatorial, podemos determinar a quantia de variância explicada tanto para dimensões individuais quanto para a solução como um todo. Alguns programas, como os de SPSS, introduzem uma medida chamada de *inércia*, que também mede variação explicada e está diretamente relacionada com o autovalor.

### ***Determinação do número de dimensões***

O número máximo de dimensões que pode ser estimado é um a menos do que o menor número entre a quantia de linhas ou de colunas. Por exemplo, com seis colunas e oito linhas, o número máximo de dimensões seria cinco, o que corresponde a seis (o número de colunas) menos um.

O pesquisador seleciona o número de dimensões com base no nível geral de variância explicada desejada e na explicação extra ganha pelo acréscimo de uma outra dimensão. Ao avaliar dimensionalidade, o pesquisador está diante de negociações muito parecidas com outras soluções MDS ou mesmo de análise fatorial (Capítulo 3):

- Cada dimensão adicionada à solução aumenta a variância explicada da solução, mas em uma quantia decrescente (ou seja, a primeira dimensão explica a maior parte da variância, a segunda explica a segunda maior parte, e assim por diante).
- Adicionar dimensões aumenta a complexidade do processo de interpretação; mapas perceptuais com mais de três dimensões se tornam cada vez mais complexos para análise.

O pesquisador deve equilibrar o desejo por variância explicada maior versus a solução mais complexa que possa afetar a interpretação. Uma dica prática é que dimensões com inércia (autovalores) maiores que 0,2 devem ser incluídas na análise.

### ***Estimação do modelo***

Vários programas de computador estão à disposição para realizar a análise de correspondência. Entre os programas mais populares, estão ANACOR e HOMALS, disponíveis no SPSS; CA de BMDP; CORRAN e CORRESP de PC-MDS [24]; e MAPWISE [21]. Um grande número de aplicações especializadas tem surgido em disciplinas específicas como ecologia, geologia e muitas das ciências sociais.

## **Estágio 5: Interpretação dos resultados**

Logo que a dimensionalidade tiver sido estabelecida, o pesquisador se defronta com duas tarefas: interpretar as dimensões para compreender a base para a associação entre categorias e avaliar o grau de associação entre categorias, dentro de uma linha/coluna ou entre linhas e colunas. Fazendo isso, o pesquisador ganha uma compreensão a respeito das dimensões inerentes sobre as quais o mapa perceptual se baseia, juntamente com a associação derivada de qualquer conjunto específico de categorias.

### ***Definição do caráter das dimensões***

Se o pesquisador está interessado em definir o caráter de uma ou mais dimensões em termos das categorias de linha ou coluna, medidas descritivas em cada programa de computador indicam a associação de cada categoria a uma dimensão específica. Por exemplo, em SPSS a medida de inércia (usada para avaliar o grau de variância explicada) é decomposta ao longo das dimensões. Semelhantes, em caráter, a cargas fatoriais, esses valores representam a extensão da associação para cada categoria individualmente com cada dimensão. O pesquisador pode então nomear cada dimensão em termos das categorias mais associadas com ela.

Além de representar a associação de cada categoria com cada dimensão, os valores de inércia podem ser totalizados ao longo de dimensões em uma medida coletiva. Fazendo isso, ganhamos uma medida empírica do grau em que cada categoria está representada ao longo de todas as dimensões. Conceitualmente, esta medida é similar à medida de comunalidade de análise fatorial (ver Capítulo 3).

### ***Avaliação da associação entre categorias***

A segunda tarefa na interpretação é identificar a associação de uma categoria com outras, o que pode ser feito visualmente ou por meio de medidas empíricas. Qualquer que seja a técnica empregada, o pesquisador deve primeiramente escolher os tipos de comparação a serem feitas e então a normalização adequada para a comparação selecionada. Os dois tipos de comparação são:

1. *Entre categorias da mesma linha ou coluna.* Aqui o foco é apenas sobre linhas ou colunas, como quando se examinam as categorias de uma escala para ver se elas podem ser combinadas. Esses tipos de comparações podem ser feitos diretamente a partir de qualquer análise de correspondência.
2. *Entre linhas e colunas.* Uma tentativa de relacionar a associação entre uma categoria de linha e uma de coluna. Este tipo mais comum de comparação relaciona categorias ao longo de dimensões (como em nosso exemplo anterior, vendas de produtos associadas com categorias etárias). Contudo, desta vez há algum debate na adequação da comparação entre categorias de linha e de coluna. Em um sentido estrito, distâncias entre pontos representando categorias só podem ser feitas dentro de uma linha ou coluna. É considerada inadequada a comparação direta de uma categoria de linha e uma de coluna. É apropriado fazer generalizações referentes às dimensões e à posição de cada categoria sobre tais dimensões. Assim, a posição relativa de categorias de linha e coluna pode ser definida dentro dessas dimensões, mas não deve haver comparação direta.

Alguns programas de computador fornecem um procedimento de normalização para viabilizar essa comparação direta. Se apenas um procedimento de normalização de linha ou coluna está disponível, técnicas alternativas são propostas para tornar todas as categorias comparáveis [2, 21], mas ainda há discordâncias quanto ao seu sucesso [12]. Nos casos em que as comparações diretas não são possíveis, a



correspondência geral ainda vale e padrões específicos podem ser distinguidos.

Os objetivos da pesquisa podem se concentrar na avaliação das dimensões ou na comparação de categorias, e o pesquisador é encorajado a fazer ambas as interpretações já que elas reforçam uma a outra. Por exemplo, a comparação de categorias de linha versus de coluna sempre pode ser complementada com a compreensão da natureza das dimensões para fornecer uma perspectiva mais abrangente do posicionamento das categorias em vez de simplesmente comparações específicas. Analogamente, a avaliação da comparação específica de categorias pode dar especificidade à interpretação das dimensões.

## Estágio 6: Validação dos resultados

A natureza composicional da análise de correspondência fornece maior especificidade para o pesquisador validar os resultados. Fazendo isso, o pesquisador deve buscar avaliar duas questões-chave relativas à generalidade de dois elementos:

- *Amostra.* Como ocorre com todas as técnicas MDS, deve-se enfatizar a garantia da generalidade por meio de análises de subamostras ou múltiplas amostras.
- *Objetos.* A generalidade dos objetos (representada individualmente e como um conjunto pelas categorias) também deve ser estabelecida. A sensibilidade dos resultados à adição ou eliminação de uma categoria pode ser avaliada. A meta é avaliar se a análise depende de apenas poucos objetos e/ou atributos.

Em qualquer caso, o pesquisador deve entender o verdadeiro significado dos resultados em termos das categorias sendo analisadas. A natureza inferencial da análise de correspondência, como outros métodos MDS, requer estrita confiança na representatividade e generalidade da amostra de respondentes e objetos (categorias) sob análise.

## Visão geral da análise de correspondência

A análise de correspondência apresenta ao pesquisador diversas vantagens, variando da natureza generalizada dos dados de entrada ao desenvolvimento de mapas perceptuais únicos:

- A simples tabulação cruzada de múltiplas variáveis categóricas, como atributos de produtos versus marcas, pode ser representada em um espaço perceptual. Essa abordagem permite ao pesquisador analisar as respostas existentes ou reunir respostas no tipo menos restritivo de medida, o nível categórico ou nominal. Por exemplo, o respondente precisa avaliar somente com respostas do tipo sim ou não um conjunto de objetos quanto a alguns atributos. Essas respostas podem então ser agregadas em uma tabela cruzada e analisadas. Outras técnicas, como a análise fatorial, exigem avaliações na escala intervalar de cada atributo para cada objeto.

- A CA retrata não somente as relações entre as linhas e colunas, mas também as relações entre as categorias de linhas ou colunas. Por exemplo, se as colunas fossem atributos, múltiplos atributos próximos teriam perfis similares ao longo de produtos, formando um grupo de atributos muito semelhante a um fator de análise de componentes principais.
- A CA pode fornecer uma visão conjunta de categorias das linhas e colunas na mesma dimensionalidade. Certas modificações de programas permitem comparações entre pontos nos quais a proximidade relativa está diretamente relacionada com a maior associação entre pontos separados [1, 21]. Quando essas comparações são possíveis, permitem que categorias das linhas e colunas sejam examinadas simultaneamente. Uma análise desse tipo capacitaria o pesquisador a identificar grupos de produtos caracterizados por atributos em grande proximidade.

Junto com as vantagens da CA, porém, surgem algumas desvantagens ou limitações.

- A técnica é descritiva e nada adequada ao teste de hipóteses. Se a relação quantitativa de categorias é desejada, métodos como modelos log-lineares são sugeridos. A CA é mais adequada à análise exploratória de dados.
- A CA, como acontece com muitos métodos de redução de dimensionalidade, não dispõe de procedimento para determinar conclusivamente o número apropriado de dimensões. Como ocorre com métodos similares, o pesquisador deve equilibrar interpretabilidade com parcimônia da representação dos dados.

## REGRAS PRÁTICAS 9-4

### Análise de correspondência

- A análise de correspondência (CA) é mais adequada para pesquisa exploratória e não é adequada para teste de hipóteses
- A CA é uma forma de técnica composicional que demanda especificação de objetos e atributos a serem comparados
- A análise de correspondência é sensível a observações atípicas, as quais devem ser eliminadas antes de se usar tal técnica
- O número de dimensões a serem mantidas na solução se baseia em:
  - Dimensões com inércia (autovalores) maiores que 0,2
  - Dimensões suficientes para atender os objetivos da pesquisa (geralmente duas ou três)
- Dimensões podem ser “nomeadas” com base na decomposição de medidas de inércia ao longo de uma dimensão:
  - Esses valores mostram a extensão de associação para cada categoria individualmente com cada dimensão
  - Elas podem ser usadas para descrição como as cargas em análise fatorial

- A técnica é bastante sensível a dados atípicos, em termos de linhas ou colunas (p.ex., atributos ou marcas). Além disso, para fins de generalização, o problema de objetos ou atributos omitidos é crítico.

No geral, a análise de correspondência provê uma valiosa ferramenta analítica para um tipo de dado (não-métrico) que normalmente não é o ponto focal de técnicas multivariadas. A análise de correspondência também fornece ao pesquisador uma técnica composicional complementar ao MDS, para tratar de questões nas quais a comparação direta de objetos e atributos é preferível.

## ILUSTRAÇÃO DO MDS E DA ANÁLISE DE CORRESPONDÊNCIA

Para demonstrar o uso de técnicas MDS, examinamos dados reunidos em diversas entrevistas com representantes de companhias a partir de uma amostra representativa de clientes em potencial. No decorrer da análise do mapeamento perceptual, aplicamos métodos decomposicionais (MDS) e composicionais (análise de correspondência). A discussão prossegue em quatro seções:

1. Exame dos três estágios iniciais do processo de construção do modelo (objetivos da pesquisa, planejamento da pesquisa e suposições) que são comuns aos dois métodos
2. Discussão dos próximos dois estágios (estimação de modelo e interpretação) para métodos decomposicionais de MDS
3. Discussão dos mesmos dois estágios para o método composicional (análise de correspondência) aplicado à mesma amostra de respondentes
4. Uma olhada no sexto estágio do processo de construção de modelo (validação) por meio de comparação dos resultados dos dois tipos de métodos.

A aplicação de técnicas composicionais e decomposicionais permite ao pesquisador conquistar visões exclusivas de cada técnica enquanto também estabelece uma base de comparação entre cada método.

### Estágio 1: Objetivos do mapeamento perceptual

Um propósito comum da pesquisa que lida com mapeamento perceptual é explorar a imagem e competitividade de uma firma. Essa exploração inclui a abordagem de percepções de um conjunto de firmas no mercado, bem como uma investigação de preferências entre clientes em potencial.

Neste exemplo, a HBAT emprega técnicas de mapeamento perceptual em um plano de duas fases:

1. Identificação da posição de HBAT em um mapa perceptual de grandes competidores no mercado

com uma compreensão das comparações de dimensões usadas por clientes em potencial

2. Avaliação das preferências por HBAT relativamente a competidores importantes

Concentra-se interesse particular no exame das dimensões de avaliação que possam ser mais subjetivas ou afetivas na composição a ser medida por escalas convencionais. Além disso, a intenção é criar um único mapa perceptual geral pela combinação de posições de objetos e sujeitos, tornando muito mais diretas as posições relativas de objetos e clientes para análise de segmentação

Na busca desses objetivos, o pesquisador deve abordar três questões fundamentais que ditam o caráter básico dos resultados: objetos a serem considerados para comparação, o uso de dados de preferência ou de similaridade, e o emprego de análise desagregada ou agregada. Cada uma dessas questões será tratada na discussão a seguir.

### *Identificação de objetos para inclusão*

Uma decisão crítica para qualquer análise de mapa perceptual é a seleção dos objetos a serem comparados. Uma vez que julgamentos são feitos baseados na similaridade de um objeto com outro, a inclusão ou exclusão de objetos pode ter um grande impacto. Por exemplo, a exclusão de uma firma com características ímpares em relação a outras pode ajudar a revelar comparações entre empresas ou até de dimensões não detectadas de outra forma. Analogamente, a exclusão de firmas de destaque ou relevantes sob outra perspectiva pode afetar os resultados de maneira semelhante.

Em nosso exemplo, os objetos de estudo são a HBAT e seus nove principais concorrentes. Para entender as percepções dessas companhias concorrentes, executivos de nível médio que representam potenciais clientes são pesquisados quanto às suas percepções da HBAT e de concorrentes. Espera-se que os mapas perceptuais resultantes retratem o posicionamento da HBAT no mercado.

### *Análise baseada em dados de similaridade ou de preferência*

A escolha de dados de similaridade ou de preferência depende dos objetivos básicos da análise. Dados de similaridade fornecem a comparação mais direta de objetos com base em seus atributos, enquanto dados de preferência permitem uma avaliação direta do sentimento do respondente em relação a um objeto. É possível, através do uso de múltiplas técnicas, combinar os dois tipos de dados se ambos são coletados.

Para esta análise, reunir tanto dados de similaridade quanto de preferência viabiliza aos pesquisadores tratar de cada um dos objetivos de pesquisa já mencionados. Dados de similaridade são o tipo básico de informação usada na análise, com dados de preferência usados em análises suplementares para avaliação de ordem de preferência entre objetos.

### ***Uso de uma análise desagregada ou agregada***

A decisão final é sobre o uso de análise agregada ou desagregada individualmente ou em comum. Análise agregada fornece uma perspectiva geral sobre a amostra como um todo em uma só análise, com mapas perceptuais representando as percepções compostas de todos os respondentes. Análise desagregada permite uma análise individualizada, na qual todos os respondentes podem ser retratados com seus próprios mapas perceptuais. Também é possível combinar esses dois tipos de análise de forma que resultados individuais são retratados em conjunto com os resultados agregados.

Neste exemplo da HBAT, a maior parte da análise será conduzida no nível agregado sempre que possível, apesar de que em certos casos os resultados desagregados também serão apresentados. Os resultados agregados se aproximam mais dos objetivos da pesquisa, os quais são um retrato geral da HBAT em relação aos maiores concorrentes. Se a pesquisa subsequente fosse mais concentrada em segmentação ou questões que diretamente envolvessem indivíduos, então a análise desagregada seria mais adequada.

Tendo tratado desses três problemas, podemos prosseguir com questões relativas ao planejamento específico de pesquisa e administração da análise de mapeamento perceptual.

## **Estágio 2: Projeto de pesquisa do estudo do mapeamento perceptual**

Com os objetivos definidos para a análise de mapeamento perceptual, os pesquisadores da HBAT devem, a seguir, tratar de um conjunto de decisões focando aspectos de planejamento de pesquisa que definem os métodos usados e as firmas específicas a serem estudadas. Fazendo isso, eles também definem os tipos de dados que precisam ser coletados para executar a análise desejada. Cada uma dessas questões é discutida na próxima seção.

### ***Seleção de métodos decomposicionais ou composicionais***

A escolha entre métodos decomposicionais (livres de atributos) ou composicionais (baseados em atributos) gira em torno da especificidade que o pesquisador deseja.

Na abordagem decomposicional, o respondente fornece apenas percepções ou avaliações gerais a fim de prover a medida de similaridade mais direta. Contudo, o pesquisador fica com pouca evidência objetiva de como essas percepções são formadas ou da base em que elas são formadas. Em contrapartida, a abordagem composicional fornece alguns pontos de referência (p. ex., atributos) quando avalia similaridades, mas aí devemos estar cientes dos problemas em potencial quando atributos relevantes são omitidos.

Neste exemplo, uma combinação de técnicas decomposicionais e composicionais é empregada. Primeiro, técnicas MDS tradicionais usando medidas gerais de similaridade fornecem mapas perceptuais que podem então ser interpretados usando dados adicionais de atributos e de preferência. Além disso, um método composicional (análise de correspondência) é utilizado como abordagem complementar no mapeamento perceptual, contribuindo para sua habilidade de simultaneamente retratar firmas e atributos em um só mapa.

### ***Seleção de firmas para análise***

Ao selecionar empresas para análise, o pesquisador deve resolver duas questões. Primeiro, será que todas as firmas são comparáveis e relevantes para os propósitos deste estudo? Segundo, o número de firmas incluídas é suficiente para retratar a dimensionalidade desejada? O planejamento da pesquisa para tratar de cada questão é discutido aqui.

Este estudo inclui nove concorrentes, mais a HBAT, representando todas as principais firmas nesta indústria e tendo coletivamente mais de 85% de todas as vendas. Além disso, elas são consideradas representativas de todos os potenciais segmentos existentes no mercado. Todas as demais firmas não incluídas na análise são tidas como concorrentes secundários em relação a uma ou mais das empresas já incluídas.

Incluindo 10 empresas, os pesquisadores podem estar razoavelmente certos de que mapas perceptuais de duas dimensões podem ser identificados e retratados. Apesar de isso envolver uma tarefa de avaliação um pouco extensa por parte dos respondentes, foi considerado necessário incluir este conjunto de firmas para permitir aos pesquisadores uma estrutura multidimensional dentro da qual eles descrevam informações de atributos e preferência.

### ***Métodos não-métricos versus métricos***

A escolha entre métodos não-métricos e métricos se baseia no tipo de análise a ser executada (p.ex., composicional ou decomposicional) e nos programas a serem

utilizados. Em alguns casos, as exigências por programas específicos (p. ex., a análise de correspondência) ditam a abordagem, mas na maioria das vezes ambas as opções estão disponíveis.

No estudo HBAT, ambos os métodos, métricos e não-métricos, são usados. As análises de escalonamento multidimensional são executadas exclusivamente com dados métricos (avaliações de similaridades, preferências e de atributos). A análise de correspondência executa uma análise não-métrica usando dados na forma de escores cruzados de frequência.

### ***Coleta de dados de similaridade e de preferência***

Uma consideração importante na decisão sobre o uso de similaridades ou preferências tem a ver com os objetivos da pesquisa: a análise se concentra na compreensão sobre como os objetos se comparam conforme os antecedentes de escolha (ou seja, similaridades baseadas em atributos de objetos) ou segundo os resultados da escolha (ou seja, preferências)? Ao escolher uma abordagem, o analista deve então inferir sobre a outra por meio de análise adicional. Por exemplo, se similaridades são escolhidas como os dados de entrada, o pesquisador ainda está incerto sobre quais escolhas seriam feitas em qualquer tipo de decisão. Analogamente, se preferências são analisadas, o pesquisador não tem base direta para entender os determinantes de escolha a menos que alguma análise adicional seja realizada.

O estudo da imagem da HBAT é constituído de entrevistas em profundidade com 18 administradores de nível médio de diferentes empresas. A partir dos objetivos da pesquisa, a principal meta é compreender as semelhanças de firmas com base em seus atributos. Logo, atenção é dada a dados de similaridade para uso em análise de escalonamento multidimensional e em avaliações não-métricas de atributos para a análise de correspondência. No decorrer das entrevistas, entretanto, tipos adicionais de dados foram coletados para uso na análise MDS, incluindo avaliações de atributos de empresas e preferências por empresas em diferentes situações de compra.

### ***Dados de similaridades***

O ponto de partida para a coleta de dados para a análise MDS foi obter as percepções dos respondentes quanto à similaridade ou dissimilaridade entre a HBAT e nove empresas concorrentes no mercado.

Julgamentos de similaridades foram feitos com a abordagem de comparação de pares de objetos. Os 45 pares de empresas  $[(10 \times 9)/2]$  foram apresentados aos res-

pondentes, os quais indicaram o quanto umas são parecidas com as outras em uma escala de 9 pontos, sendo 1 “nada similares” e 9 “muito similares”. Note que os valores têm de ser transformados porque valores crescentes para avaliações de similaridades indicam maior semelhança, o oposto de uma medida de similaridade baseada em distância.

### ***Avaliações de atributos***

Além dos julgamentos de similaridades, as avaliações de cada empresa em uma série de atributos foram obtidas para fornecer algum meio objetivo de descrição das dimensões identificadas nos mapas perceptuais. Essas avaliações, conseguidas com dois métodos, seriam usadas em ambas as análises, MDS e de correspondência.

Oito dos 10 atributos identificados como componentes dos quatro fatores do Capítulo 3 foram escolhidos para este estudo. Os 8 atributos incluídos foram  $X_6$  Qualidade do Produto;  $X_8$  Suporte Técnico;  $X_{10}$  Anúncio;  $X_{12}$  Imagem da Equipe de venda;  $X_{13}$  Preço Competitivo;  $X_{14}$  Garantia e Reclamações;  $X_{16}$  Encomenda e Cobrança; e  $X_{18}$  Velocidade de Entrega.

Dois dos atributos do conjunto original de 10 foram eliminados nesta análise. Primeiro,  $X_7$ , referente a Comércio Eletrônico, não foi usado porque cerca de metade das firmas não tinha uma presença de comércio em forma eletrônica. Além disso,  $X_9$ , Solução de Reclamação, que é fortemente baseado em experiência, também foi omitido porque a avaliação feita por aqueles que não são clientes seria difícil para os respondentes.

Para as avaliações métricas usadas em MDS, cada firma foi avaliada em uma escala de 6 pontos quanto a cada atributo. Para a análise de correspondência, avaliações não-métricas foram coletadas solicitando-se que cada respondente escolhesse as firmas melhor caracterizadas por conta de cada atributo. Como no método “escolha qualquer um” [14, 15], o respondente poderia selecionar qualquer número de firmas para cada atributo.

### ***Avaliações de preferência***

O tipo final de dados avaliou as preferências de cada respondente em um contexto específico de escolha. Esses dados devem ser usados em conjunto com os mapas perceptuais derivados no escalonamento multidimensional para fornecer uma visão sobre a correspondência de semelhança e julgamentos de preferência.

Três diferentes tipos de situação de compra – uma recompra simples, uma recompra modificada e uma situação de nova compra – foram avaliados pelos respondentes. Em cada situação, os respondentes classi-



ficaram as empresas em ordem de preferência para aquele contexto particular de compra. Por exemplo, na situação de recompra simples, o respondente indicou a empresa preferida para a simples recompra de produtos (posto de ordenação = 1), a próxima preferida (posto de ordenação = 2) e assim por diante. Preferências semelhantes foram reunidas para as duas situações de compra restantes.

### Estágio 3: Suposições no mapeamento perceptual

As suposições de MDS e CA lidam principalmente com a comparabilidade e representatividade dos objetos avaliados e dos respondentes. As técnicas em si impõem poucas limitações aos dados, mas o sucesso delas se baseia em diversas características dos dados.

Com relação à amostra, o plano amostral enfatizou a obtenção de uma amostra representativa de clientes da HBAT. Além disso, tomou-se cuidado para obter respondentes de posição e conhecimento de mercado comparáveis. Como a HBAT e as outras empresas atendem um mercado bastante distinto, todas as firmas avaliadas no mapeamento perceptual devem ser conhecidas, garantindo-se que discrepâncias de posicionamento possam ser atribuídas a diferenças perceptuais entre respondentes.

### Escalonamento multidimensional: Estágios 4 e 5

Após ter especificado as 10 empresas a serem incluídas no estudo de imagem, a administração da HBAT especificou que as duas abordagens, decomposicional (MDS) e com-

posicional (CA), deveriam ser empregadas para construir os mapas perceptuais. Primeiro discutimos diversas técnicas decomposicionais, e então examinamos uma abordagem composicional para mapeamento perceptual.

### Estágio 4: Obtenção de resultados MDS e avaliação do ajuste geral

O processo de desenvolvimento de um mapa perceptual é fundamental para uma solução MDS, mas pode variar bastante em termos dos tipos de dados de entrada e análises associadas executadas. Nesta seção discutimos primeiramente o processo de desenvolvimento de um mapa perceptual com base em julgamentos de similaridade. Em seguida, com o mapa perceptual estabelecido, examinamos o processo para incorporação de julgamentos de preferência no mapa perceptual já existente.

**Desenvolvimento e análise do mapa perceptual.** O IN-DSCAL [4] foi usado para desenvolver um mapa perceptual, composto ou agregado, e as medidas das diferenças entre respondentes em suas percepções. Os 45 julgamentos de similaridades dos 18 respondentes foram incluídos como matrizes separadas, mas uma matriz de escores médios foi calculada para ilustrar o padrão geral de similaridades (ver Tabela 9-4). A tabela também especifica as altas similaridades (maiores que 6,0), bem como a menor similaridade para cada empresa. Com essas relações, os padrões básicos podem ser identificados e estão disponíveis para comparação com o mapa resultante.

**Estabelecimento da dimensionalidade apropriada.** A primeira análise dos resultados do MDS é determinar a dimensionalidade apropriada e retratar os resultados em um mapa perceptual. Para fazer isso, o pesquisador deve

**TABELA 9-4** Médias das avaliações de similaridade para HBAT e nove firmas concorrentes

Firma	Firma									
	HBAT	A	B	C	D	E	F	G	H	I
HBAT	0,00									
A	6,61	0,00								
B	5,94	5,39	0,00							
C	2,33	2,61	3,44	0,00						
D	2,56	2,56	4,11	6,94	0,00					
E	4,06	2,39	2,17	4,06	2,39	0,00				
F	2,50	3,50	4,00	2,22	2,17	4,06	0,00			
G	2,33	2,39	3,72	2,67	2,61	3,67	2,28	0,00		
H	2,44	4,94	6,61	2,50	7,06	5,61	2,83	2,56	0,00	
I	6,17	6,94	2,83	2,50	2,50	3,50	6,94	2,44	2,39	0,00
<b>Avaliações de similaridade máxima e mínima</b>										
Similaridade maior que 6,0	A, I	HBAT I	H	D	C, H	Nenhum	I	Nenhum	B, D	HBAT A, F
Menor similaridade	C, G	E, G	E	F	F	B	C	F	I	H

*Nota:* Avaliações de similaridade estão em uma escala de 9 pontos (1 = nada semelhantes, 9 = muito semelhantes).

considerar os índices de ajuste em cada dimensionalidade e a própria habilidade em interpretar a solução.

A Tabela 9-5 mostra os índices de ajuste para soluções de duas a cinco dimensões (uma solução unidimensional não foi considerada uma alternativa viável para 10 empresas). Como mostra a tabela, existe uma melhora substancial na mudança de duas para três dimensões, sendo que depois disso a melhora diminui e permanece consistente quando aumentamos o número de dimensões. Equilibrando essa melhora no ajuste com a crescente dificuldade de interpretação, as soluções bidimensional ou tridimensional parecem ser as mais adequadas. Para fins de ilustração, a solução bidimensional é escolhida para posterior análise, mas os métodos que aqui discutimos poderiam ser aplicados à solução tridimensional com a mesma facilidade. O pesquisador é encorajado a explorar outras soluções

para avaliar se alguma conclusão substancialmente diferente seria alcançada com base na dimensionalidade escolhida.

**Criação do mapa perceptual.** Com a dimensionalidade estabelecida em duas dimensões, o próximo passo é posicionar cada objeto (firma) no mapa perceptual. Lembre que a base para o mapa (neste caso, similaridade) define como os objetos podem ser comparados.

O mapa perceptual agregado bidimensional é exibido na Figura 9-12. A HBAT é mais proximamente associada à empresa A, com respondentes considerando-as quase idênticas. Outros pares de empresas consideradas altamente similares com base em sua proximidade são E e G, D e H, e F e I. Comparações também podem ser feitas entre essas empresas e a HBAT. A HBAT difere de C,

(Continua)


**TABELA 9-5** Avaliação do ajuste geral do modelo e determinação da dimensionalidade adequada

Dimensionalidade da solução	Medidas médias de ajuste <sup>a</sup>			
	Desajuste <sup>b</sup>	Variação percentual	$R^2$ <sup>c</sup>	Variação percentual
5	0,20068	–	0,6303	–
4	0,21363	6,4	0,5557	11,8
3	0,23655	10,7	0,5007	9,9
2	0,30043	27,0	0,3932	21,5

<sup>a</sup>Média ao longo de 18 soluções individuais

<sup>b</sup>Fórmula de desajuste de Kruskal

<sup>c</sup>Proporção de avaliações de similaridade original explicadas por dados (distâncias) escalonados do mapa perceptual



**FIGURA 9-12** Mapa perceptual de HBAT e principais concorrentes.

(Continuação)

E e G principalmente na dimensão II, ao passo que a dimensão I diferencia a HBAT mais claramente das empresas B, C, D e H em uma direção, e das empresas F e I em uma outra direção. Todas essas diferenças são refletidas em suas posições relativas no mapa perceptual. Comparações parecidas podem ser feitas entre todos os conjuntos de empresas. Para entender as fontes dessas diferenças, porém, o pesquisador deve interpretar as dimensões.

Antes de prosseguir com a adição de dados de preferência à análise, o pesquisador deve examinar os resultados para identificar quaisquer observações atípicas em potencial e verificar a suposição de homogeneidade de respondentes. Cada uma dessas questões é tratada antes que o processo de interpretação comece.

**Avaliação de potenciais observações atípicas.** No processo de seleção da dimensionalidade adequada, uma medida geral de ajuste (desajuste) foi examinada. No entanto, tal medida não retrata de forma alguma o ajuste da solução para comparações individuais. Tal análise pode ser feita visualmente por meio de um diagrama de dispersão de distâncias reais (valores escalonados de similaridade) versus distâncias ajustadas do mapa perceptual. Cada ponto representa um único julgamento de similaridade entre dois objetos, com ajuste pobre espelhando pontos atípicos no gráfico. Dados atípicos são um conjunto de julgamentos de similaridade que refletem consistentemente ajuste ruim para um objeto ou respondente individual. Se um conjunto consistente de objetos ou in-

divíduos é identificado como atípico, ele pode ser considerado para eliminação.

A Figura 9-13 representa o diagrama de dispersão de valores de similaridade versus as distâncias derivadas do programa MDS. Neste caso, não surge qualquer padrão consistente de pontos atípicos para uma firma ou respondente em especial para torná-lo candidato à eliminação da análise.

**Teste da suposição de homogeneidade para respondentes.** Além de desenvolver o mapa perceptual composto, o INDSCAL também fornece os meios para avaliar uma das suposições de MDS, a homogeneidade das percepções dos respondentes. Para cada respondente, calculam-se pesos indicativos da correspondência de seu próprio espaço perceptual com o mapa perceptual agregado. Esses pesos fornecem uma medida de comparação entre os respondentes, pois os respondentes com pesos similares têm mapas perceptuais individuais similares. O INDSCAL também fornece uma medida de ajuste para cada sujeito, correlacionando os escores computados com as avaliações de similaridades originais do respondente.

A Tabela 9-6 contém os pesos e medidas de ajuste para cada respondente, e a Figura 9-14 é uma representação gráfica dos respondentes individuais baseada em seus pesos. O exame dos pesos (Tabela 9-6) e da Figura 9-14 revela que os respondentes são bem homogêneos em suas percepções,

(Continua)





FIGURA 9-13 Diagrama de dispersão de ajuste linear.

**TABELA 9-6** Medidas de diferenças individuais em mapeamento perceptual: medidas de ajuste e pesos dimensionais para respondentes específicos

Sujeito	<i>Medidas de ajuste</i>		<i>Pesos dimensionais</i>	
	Desajuste <sup>b</sup>	$R^{2c}$	Dimensão I	Dimensão II
1	0,358	0,274	0,386	0,353
2	0,297	0,353	0,432	0,408
3	0,302	0,378	0,395	0,472
4	0,237	0,588	0,572	0,510
5	0,308	0,308	0,409	0,375
6	0,282	0,450	0,488	0,461
7	0,247	0,547	0,546	0,499
8	0,302	0,332	0,444	0,367
9	0,320	0,271	0,354	0,382
10	0,280	0,535	0,523	0,511
11	0,299	0,341	0,397	0,429
12	0,301	0,343	0,448	0,378
13	0,292	0,455	0,497	0,456
14	0,302	0,328	0,427	0,381
15	0,290	0,371	0,435	0,426
16	0,311	0,327	0,418	0,390
17	0,281	0,433	0,472	0,458
18	0,370	0,443	0,525	0,409
Média <sup>a</sup>	0,300	0,393		

<sup>a</sup>Média ao longo de 18 soluções individuais<sup>b</sup>Fórmula de desajuste de Kruskal<sup>c</sup>Proporção de avaliações de similaridade original explicadas por dados escalonados (distâncias) do mapa perceptual**FIGURA 9-14** Pesos individuais de sujeitos.



(Continuação)

pois os pesos mostram poucas diferenças relevantes em cada dimensão, e nenhum agrupamento distinto de indivíduos emerge. Na Figura 9-14 todos os pesos individuais recaem sobre uma reta, indicando um peso consistente entre as dimensões I e II.

A distância de cada peso individual em relação à origem indica seu nível de ajuste com a solução. Os melhores ajustes são mostrados pelas maiores distâncias da origem. Logo, os respondentes 4, 7 e 10 têm o mais alto ajuste, e os respondentes 1 e 9, o mais baixo ajuste. Os valores de ajuste exibem consistência relativa tanto em desajuste quanto em  $R^2$ , com valores médios de 0,300 (desajuste) e 0,393 ( $R^2$ ). Além disso, todos os respondentes são bem representados pelo mapa perceptual composto, sendo a menor medida de ajuste 0,27. Assim, nenhum indivíduo deve ser eliminado devido a pouco ajuste na solução bidimensional.

**Incorporação de preferências no mapa perceptual.** Até agora, lidamos apenas com julgamentos de empresas baseados em similaridades, mas muitas vezes podemos querer estender a análise para o processo de tomada de decisões e entender as preferências do respondente pelos objetos (no caso, empresas). Para tanto, podemos empregar técnicas MDS adicionais que permitem a estimação de pontos ideais, a partir dos quais as preferências por objetos podem ser determinadas.

Nesse exemplo, usamos um método externo de formação de preferência (PREFMAP [6]) que utiliza os mapas perceptuais agregados obtidos na seção anterior e os combina com os julgamentos de preferência fornecidos pelos respondentes. O resultado é a identificação de pontos ideais para indivíduos e para o respondente médio no mapa perceptual.

**Geração de avaliações de preferência.** Preferências diferem de comparações de similaridade no sentido de que os respondentes abordam a questão de preferência entre objetos em um contexto específico de decisão. Tais avaliações podem diferir sensivelmente de julgamentos de similaridade ou entre contextos de decisão (ou seja, comprar um produto como presente para alguém versus para uso pessoal). É essencial que o contexto apropriado de decisão seja analisado para atender aos objetivos da pesquisa.

Como descrito anteriormente, os respondentes foram solicitados a detalharem suas preferências quanto a firmas em três situações de compra. Aqui examinamos as preferências para firmas na nova situação de compra. Para fins de ilustração, examinamos as preferências de cinco respondentes. As ordenações de preferência para esses cinco respondentes são dadas na Tabela 9-7.

**Cálculo de pontos ideais.** Usando o mapa perceptual anteriormente obtido e as avaliações de preferência, o programa pode estimar pontos ideais tanto do ponto de vista vetorial quanto pontual. A principal diferença entre essas duas abordagens é seu método de interpretação, com os pontos ideais pontualmente representados sendo avaliados diretamente por sua proximidade com posições individuais de firmas, enquanto uma abordagem vetorial representa preferência com base em projeções para o vetor (ver discussão anterior sobre esses dois métodos).

Nessa situação, a administração da HBAT decidiu-se pelas representações pontuais, o que resultou na derivação de pontos ideais para os cinco respondentes, mais um ponto

(Continua)

TABELA 9-7 Dados de preferência da nova situação de compra para respondentes selecionados

Sujeito	Firma										Ajuste <sup>a</sup>
	HBAT	A	B	C	D	E	F	G	H	I	
1	2	3	5	6	7	4	10	8	1	9	0,787
	-0,867	-0,972	-0,920	-1,096	-1,095	-0,636	-0,264	-1,054	-0,854	-0,371	
2	5	2	7	6	9	3	4	1	10	8	0,961
	-1,049	-1,056	-0,622	-0,906	-0,642	-1,111	-0,879	-1,596	-0,413	-0,825	
3	4	1	8	7	6	9	3	5	10	2	0,855
	-0,894	-0,868	-0,448	-0,133	-0,106	-0,449	-0,726	-0,576	-0,132	-0,779	
4	4	3	10	2	7	8	6	1	9	5	0,884
	-1,098	-1,128	-0,736	-1,060	-0,813	-1,136	-0,822	-1,672	-0,544	-0,790	
5	4	1	8	7	9	3	5	2	10	6	0,977
	-0,905	-0,868	-0,401	-0,362	-0,188	-0,769	-0,870	-1,019	-0,126	-0,838	
	NA	NA	NA	NA	NA	NA	NA	NA	NA	NA	
Média	-0,916	-0,931	-0,580	-0,668	-0,525	-0,776	-0,666	-1,140	-0,370	-0,674	0,990

Nota: Valores no topo de cada célula são ordenações originais de preferência, enquanto a parte de baixo é a distância quadrada (com sinal) da firma até o ponto ideal. NA indica ordenações médias não disponíveis.

<sup>a</sup>Ajuste é a correlação quadrada entre preferências e distâncias com sinal.

(Continuação)

ideal para o sujeito médio. Os resultados são mostrados na Figura 9-15. As distâncias de cada empresa até os pontos ideais são fornecidas na Tabela 9-7. Valores menores indicam uma maior proximidade do ponto ideal.

**Interpretação da solução baseada em preferência.** A inclusão de julgamentos de preferência é uma tentativa de estender o mapa perceptual com base em julgamentos de similaridade em um contexto de decisão. Deve ser observado que uma técnica alternativa é utilizar julgamentos de preferência como a base para o mapa perceptual, caso em que resultados diferentes podem ocorrer. Tal método, contudo, confina a interpretação a apenas um contexto específico de decisão, enquanto a abordagem descrita aqui usa o mapa perceptual mais generalizado radicado em similaridade em um contexto decisório específico.

A Figura 9-15 retrata todos os respondentes que formam um grupo geral de certa forma agregado em torno da média, o que indica uma uniformidade geral em preferências. No entanto, ainda podemos detectar diferenças de proximidade para o grupo como um todo tanto quanto para empresas individuais.


- Primeiro, o grupo como um todo está mais próximo das empresas C, D, F e H, ao passo que a HBAT, A, B, E e G estão de alguma forma mais afastadas. Note que, nes-

se caso, tanto a proximidade quanto a dimensionalidade são importantes. A suposição de uma análise externa é que quando você muda sua posição no mapa perceptual quanto às dimensões, pode mudar sua proximidade dos pontos ideais e sua ordem de preferência.

- Em termos dos respondentes individuais, algumas associações próximas indicam maiores preferências. O respondente 1 tem uma associação relativamente próxima com a empresa F, como refletido em uma avaliação de preferência de 10 (ver Tabela 9-7). Para os respondentes 3 e 5, a grande proximidade com as empresas C, D e H corresponde a um padrão consistente de preferências mais elevadas, como se mostra na Tabela 9-7. Embora esse grupo de respondentes seja relativamente homogêneo em suas preferências, como indicado por seu agrupamento, a Figura 9-15 ainda retrata a posição relativa de cada empresa não apenas em percepção, mas agora também em preferência.

### Estágio 5: Interpretação dos resultados

Logo que o mapa perceptual é estabelecido, podemos começar o processo de interpretação. Como o procedimento INDSCAL usa apenas os julgamentos de similaridade geral, a HBAT também reuniu avaliações de cada empresa em uma série de oito atributos descritivos de estratégias típicas seguidas nesta indústria. As avaliações para cada firma tiveram médias calculadas ao longo de respondentes para uma única avaliação geral usada na descrição de cada firma.



**FIGURA 9-15** Mapa de pontos ideais para respondentes selecionados e médios: situação de nova compra.

Como descrito no estágio 2, os oito atributos incluídos são  $X_6$  Qualidade de Produto;  $X_8$  Suporte Técnico;  $X_{10}$  Anúncio;  $X_{12}$  Imagem da Equipe de Venda;  $X_{13}$  Preço Competitivo;  $X_{14}$  Garantia e Reclamações;  $X_{16}$  Encomenda e Cobrança; e  $X_{18}$  Velocidade de Entrega. Esses atributos representam as variáveis individuais que compõem os quatro fatores desenvolvidos no Capítulo 3, excluindo  $X_7$ , Comércio eletrônico, e  $X_9$ , Solução de Reclamação. Os escores médios para cada firma são mostrados na Tabela 9-8.

**Uma abordagem subjetiva para interpretação.** O pesquisador pode levar a cabo diversas técnicas subjetivas para interpretação. Primeiro, as firmas podem ser caracterizadas em termos de suas avaliações de atributos com atributos distintos identificados para cada empresa. Dessa maneira, cada firma é caracterizada sobre um conjunto de atributos, com o pesquisador relacionando os mesmos com a associação entre empresas, se possível. Interpretar as dimensões é mais complicado, no sentido de que o pesquisador deve relacionar as posições das firmas com as dimensões em termos de suas características. Em ambas as abordagens, porém, o pesquisador confia em julgamento pessoal para identificar as características distintas e então relacioná-las com as posições das firmas e a interpretação resultante das dimensões.

Essas técnicas são mais apropriadas para uso em situações nas quais os objetos e as características básicas são bem estabelecidos. Então o pesquisador usa conhecimento geral de relações existentes entre atributos e objetos para auxiliar na interpretação. Em situações nas quais o pesquisador deve desenvolver tais relações e associações a partir da análise em si, as abordagens objetivas descritas na próxima seção são recomendadas, pois elas fornecem um método sistemático para identificar as questões básicas envolvidas na interpretação de objetos e dimensões.

A administração da HBAT teve acesso aos perfis de cada firma com base nos oito atributos (ver Tabela 9-8). No entanto, devido a uma vontade de evitar a introdução de qualquer viés na análise por conta de julgamento ou percepção pessoal, as abordagens subjetivas não foram usadas. Em vez disso, métodos objetivos seriam usados exclusivamente na fase de interpretação.

**Abordagens objetivas para interpretação.** Para fornecer uma maneira objetiva de interpretação, PROFIT [3], um modelo vetorial foi usado para combinar as avaliações para as posições da firma no mapa perceptual com as avaliações de atributo para cada objeto. A meta é identificar os atributos determinantes nos julgamentos de similaridade feitos por indivíduos para determinar quais atributos melhor descrevem as posições perceptuais das firmas e as dimensões.

Os resultados da aplicação dos dados de avaliação ao mapa perceptual composto são mostrados na Figura 9-16 como três grupos ou dimensões distintas de atributos. O primeiro envolve  $X_{18}$  (Velocidade de Entrega),  $X_{16}$  (Encomenda e Cobrança) e  $X_6$  (Qualidade do Produto), os quais estão todos apontados na mesma direção, e  $X_{13}$  (Preço Competitivo), que está na direção oposta à das demais três variáveis. Essa diferença na direção indica uma correspondência negativa de Competitividade de Preço em relação às outras três variáveis, o que é secundado pelas relações encontradas no Capítulo 3, onde  $X_6$  e  $X_{13}$  formam um fator, mas com  $X_6$  tendo uma carga negativa que indica uma relação negativa com  $X_{13}$ . Deve ser observado que  $X_{16}$  e  $X_{18}$  também são membros de um mesmo fator, o que apóia a proximidade dos mesmos nesta análise também.

O segundo conjunto de variáveis reflete duas outras variáveis descobertas como representantes de uma dimensão de suporte técnico (fator):  $X_8$  (Suporte Técnico) e  $X_{14}$  (Garantia e Reclamações), junto com  $X_{10}$  (Anúncio). Finalmente,  $X_{12}$  (Imagem da Equipe de Venda) anda quase perpendicularmente a todas as demais variáveis, indicando em algum grau uma dimensão separada e distinta de avaliação.

**Interpretação das dimensões.** Para interpretar as dimensões, o pesquisador procura atributos proximamente alinhados em relação ao eixo. Como o mapa perceptual é uma representação pontual, os eixos podem ser rotacionados sem qualquer impacto sobre as posições relativas.

Nesse caso, os dois grupos de atributos estão levemente inclinados em relação ao eixo original. No entanto, a leve rotação dos eixos (muito parecido com o que se faz em análise fatorial no Capítulo 3) resulta em um perfil consistente da dimensão I (horizontal), que consiste de serviço ao cliente ( $X_{16}$  e  $X_{18}$ ) e valor do produto ( $X_6$  e  $X_{13}$ ) versus a dimensão II (vertical) de marketing ( $X_{10}$  e  $X_{12}$ ) e suporte técnico ( $X_8$  e  $X_{14}$ ). Uma característica de destaque da segunda dimensão é a maneira na qual  $X_{12}$  (Imagem da Equipe de Venda) opera quase em contraste com  $X_{10}$  (Anúncio), ainda que ambas sejam altamente relacionadas. Este resultado ocorre porque firmas são distintas nessas variáveis em separado ao invés de juntamente, em contraste com as outras variáveis que pareciam seguir as relações entre variáveis anteriormente observadas.

Apesar de não ser realmente necessário realizar a rotação porque empresas podem ser comparadas diretamente quanto aos vetores de atributos, muitas vezes a rotação pode contribuir para uma compreensão mais fundamental da dimensão percebida. A rotação é especialmente útil em soluções que envolvem mais de duas dimensões.

**TABELA 9-8** Interpretação do mapa perceptual com PROFIT

AVALIAÇÕES ORIGINAIS DE ATRIBUTOS E PROJEÇÕES SOBRE VETORES AJUSTADOS												
Variáveis	Firmas											
	HBAT	A	B	C	D	E	F	G	H	I	Ajuste <sup>a</sup>	
X <sub>6</sub> Qualidade do produto	5,33 -0,5138 4,17	3,72 -0,2509 1,56	6,33 0,7045 6,06	5,56 1,0956 8,22	6,39 1,4812 7,72	4,72 -0,6007 4,28	5,28 -1,4646 3,89	5,22 -0,4450 6,33	7,33 1,2060 7,72	5,11 -1,2122 5,06	0,651  0,829	
X <sub>8</sub> Suporte técnico	-1,0905	-0,8962	0,1333	1,4956	1,4201	0,1443	-1,2587	0,4553	0,9531	-1,3563		
X <sub>10</sub> Anúncio	4,00 -1,2912	1,83 -1,1645	6,33 -0,2293	7,67 1,5350	6,00 1,1914	5,78 0,5743	5,50 -0,9644	6,11 0,9370	7,50 0,6718	4,17 -1,2600	0,785	
X <sub>12</sub> Imagem da Equipe de Venda	6,94 1,0038	7,17 1,1529	7,67 1,1057	3,22 -0,6284	4,78 0,2474	5,11 -1,4128	6,56 -0,5099	1,61 -1,6815	8,78 0,5717	3,17 0,1511	0,710	
X <sub>13</sub> Preço competitivo	6,94 0,1994	5,67 -0,0704	3,39 -0,9018	3,67 -0,8079	3,67 -1,3700	6,94 0,8879	6,44 1,4219	7,22 0,8185	4,94 -1,2092	6,11 1,0317	0,842	
X <sub>14</sub> Garantia e reclamações	5,11 -1,1133	1,22 -0,9244	5,78 0,1007	7,89 1,5053	6,56 1,4050	3,83 0,1842	4,28 -1,2369	6,94 0,5012	8,67 0,9313	4,72 -1,3530	0,720	
X <sub>16</sub> Encomenda e cobrança	5,16 -0,5571	3,47 -0,2965	6,41 0,6725	5,88 1,1322	6,06 1,4903	4,94 -0,5561	5,29 -1,4639	4,82 -0,3885	8,35 1,1998	4,65 -1,2328	0,653	
X <sub>18</sub> Velocidade de entrega	4,00 -0,4202	3,39 -0,1535	7,33 0,7696	6,11 1,0137	7,50 1,4560	4,22 -0,6928	7,17 -1,4604	4,33 -0,5627	8,22 1,2144	5,56 -1,1641	0,510	

*Nota:* Valores no topo de cada célula são avaliações originais de atributo; os números na parte de baixo são projeções para os vetores ajustados.

<sup>a</sup>Ajuste é a correlação entre as avaliações originais de atributos e as projeções vetoriais.






FIGURA 9-16 Mapa perceptual com representação vetorial de atributos.

**Caracterização das firmas.** Para determinar os valores para qualquer empresa em um vetor de atributo, precisamos calcular as projeções da empresa sobre o vetor. Para ajudar na interpretação, o programa PROFIT fornece valores de projeção para cada atributo. Esses valores fornecem uma posição relativa para cada objeto sobre o vetor de atributo. No entanto, os valores em si não são apresentados em termos da escala original do atributo. Para fornecer alguma base para comparação, médias do objeto para o atributo também são em geral consideradas.

Os valores de projeção de atributos estão listados na segunda linha de valores para cada variável na Tabela 9-8. Também estão incluídas as avaliações originais (valores na primeira linha) para ver se o vetor representa bem as percepções reais dos respondentes.

Em nosso exemplo, podemos examinar a correspondência das projeções com as avaliações de atributos para quaisquer atributos. Seleccionemos as avaliações

em  $X_8$  (Suporte Técnico). Se ordenarmos os objetos do maior para o menor, a ordem será C, D, H, G, B, I, E, HBAT, F e A. Usando as projeções vetoriais, percebemos que a ordem de empresas é C, D, H, G, E, B, A, HBAT, F e I. Esta comparação demonstra uma correspondência relativamente próxima entre os valores originais e os calculados, particularmente entre as primeiras quatro firmas. Essa ordem é confirmada pela medida estatística de ajuste para cada atributo, que é a correlação entre as avaliações originais e as projeções vetoriais. No caso de Suporte Técnico, a correlação é de 0,829.

O pesquisador não deve esperar um ajuste perfeito por várias razões. Primeiro, o mapa perceptual é baseado na avaliação geral, a qual pode não ser diretamente comparável com as avaliações. Segundo, as avaliações são submetidas ao cálculo da média ao longo dos respondentes, de modo que seus valores são determinados por diferenças

entre indivíduos, bem como diferenças entre empresas. Dados esses fatores, o nível de ajuste para os atributos é aceitável individual e coletivamente.

### **Visão geral dos resultados decomposicionais**

Os métodos decomposicionais empregados neste estudo de imagem ilustram a inerente negociação e as vantagens e desvantagens resultantes de técnicas de escalonamento multidimensional livre de atributos.

- **Vantagem:** O uso de julgamentos de similaridades gerais fornece um mapa perceptual baseado apenas nos critérios relevantes escolhidos por parte de cada respondente. O respondente pode fazer tais julgamentos com base em qualquer conjunto de critérios considerados relevantes em uma única medida de similaridade geral.

versus

- **Desvantagem:** O emprego de uma técnica livre de atributos dá origem, porém, à notável dificuldade de interpretação do mapa perceptual em termos de atributos específicos. O pesquisador é solicitado a inferir as bases para comparação entre objetos sem confirmação direta do respondente.

O pesquisador usando tais métodos deve examinar os objetivos de pesquisa e decidir se os benefícios resultantes dos mapas perceptuais desenvolvidos através de abordagens livres de atributos são mais importantes do que as limitações impostas na interpretação. Podemos examinar os resultados da análise da HBAT para avaliarmos as negociações, os benefícios e os custos.

A HBAT pode obter muitas novas idéias sobre as percepções relativas da HBAT e das demais nove firmas. Em termos de percepções, a HBAT é a mais associada com a firma A e, um pouco, com as firmas B e I. Alguns agrupamentos competitivos (p.ex., F e I, E e G) também devem ser considerados. Nenhuma empresa é consideravelmente distinta, de forma a ser considerada atípica. A HBAT pode ser considerada a média em diversos atributos ( $X_6$ ,  $X_{16}$  e  $X_{18}$ ), mas tem escores menores em diversos atributos ( $X_8$ ,  $X_{10}$  e  $X_{14}$ ) em contraste com um elevado escore para o atributo  $X_{12}$ . Finalmente, a HBAT não tem vantagem real em termos de proximidade a pontos ideais de respondente, com outras empresas, como D, H e F, estando localizadas muito mais próximas aos pontos ideais para diversos respondentes.

Esses resultados dão à HBAT uma visão não apenas de suas percepções, mas também das percepções dos outros concorrentes importantes no mercado. A habilidade de PROFIT neste exemplo para adequadamente descrever os objetos em termos do conjunto de atributos reduz as desvantagens da abordagem livre de atributos. Lembre-se, porém, que o pesquisador não está garantido em termos de compreensão sobre quais atri-

butos foram realmente usados no julgamento, estando certo apenas que esses atributos podem ser descritivos dos objetos.

### **Análise de correspondência: Estágios 4 e 5**

Uma alternativa ao mapeamento perceptual livre de atributos é a análise de correspondência (CA), um método composicional baseado em medidas não-métricas (contagens de frequência) entre objetos e/ou atributos. Neste método baseado em atributos, o mapa perceptual é um espaço conjunto, que mostra tanto atributos quanto empresas em uma mesma representação. Além disso, as posições de empresas são relativas não apenas às outras empresas incluídas na análise, mas também aos atributos selecionados.

#### **Estágio 4: Estimação de uma análise de correspondência**

A preparação de dados e o procedimento de estimação para a análise de correspondência são semelhantes, em alguns aspectos, ao processo de escalonamento multidimensional discutido anteriormente, com algumas exceções notáveis. Nas próximas seções, discutimos o método de coleta de dados usado no estudo de HBAT e, em seguida, as questões envolvidas no cálculo de similaridade e na determinação da dimensionalidade da solução.

**Coleta e preparação de dados.** Uma característica única da análise de correspondência é o emprego de dados não-métricos para retratar relações entre categorias (objetos ou atributos). Uma abordagem comum para apresentação de dados é o emprego de uma matriz de tabulação cruzada que relaciona os atributos (representados como linhas) com as avaliações de objetos/firmas (as colunas). Os valores representam o número de vezes que cada empresa é avaliada como sendo caracterizada por aquele atributo. Assim, frequências maiores indicam uma associação mais forte entre aquele objeto e o atributo em questão.

No estudo HBAT, avaliações binárias de empresas foram reunidas para cada firma em cada um dos oito atributos (ou seja, uma avaliação do tipo sim-não de cada firma sobre cada atributo). As entradas individuais na matriz de tabulação cruzada são o número de vezes que uma firma é avaliada como possuindo um atributo específico. Respondentes podem escolher qualquer número de atributos como caracterizando cada empresa. As frequências simples são fornecidas para cada firma ao longo de todo o conjunto de atributos na Tabela 9-9.

**Cálculo da medida de similaridade.** A análise de correspondência é baseada em uma transformação do valor qui-quadrado em uma medida métrica de distância, que atua como uma medida de similaridade. O valor qui-quadrado

**TABELA 9-9** Dados cruzados de frequência de descritores de atributos para HBAT e as nove firmas concorrentes

Variáveis	Firma									
	HBAT	A	B	C	D	E	F	G	H	I
$X_6$ Qualidade do produto	6	6	14	10	22	8	7	4	14	4
$X_8$ Suporte Técnico	15	18	9	2	3	15	16	7	8	8
$X_{10}$ Anúncio	15	16	15	11	11	14	16	12	14	14
$X_{12}$ Imagem da equipe de venda	4	3	1	13	9	6	3	18	2	10
$X_{13}$ Preço competitivo	15	14	6	4	4	15	14	13	7	13
$X_{14}$ Garantia e reclamações	7	18	13	4	9	16	14	5	4	16
$X_{16}$ Encomenda e cobrança	14	14	10	11	11	14	12	13	10	14
$X_{18}$ Velocidade de entrega	16	13	8	13	9	17	15	16	6	12

é calculado como a frequência real de ocorrência menos a frequência esperada. Assim, um valor negativo indica, nesse caso, que uma empresa foi avaliada menos frequentemente do que o esperado. O valor esperado para uma célula (qualquer combinação de empresa-atributo na tabulação cruzada) é baseado na frequência com que a empresa foi avaliada em outros atributos e a frequência com que outras empresas foram avaliadas naquele atributo. (Em termos estatísticos, o valor esperado é baseado nas probabilidades marginais de linha [atributo] e coluna [empresa].)

A Tabela 9-10 contém as distâncias qui-quadrados transformadas (métricas) para cada célula da tabulação cruzada da Tabela 9-9. Valores positivos elevados indicam um alto grau de correspondência entre o atributo e a empresa, e valores negativos têm uma interpretação oposta. Por exemplo, os valores elevados para a HBAT e as empresas A e F com o atributo de suporte técnico ( $X_8$ ) indicam que elas devem ficar próximas no mapa perceptual, se possível. Do mesmo modo, os valores negativos elevados para as empresas C e D na mesma variável indicariam que suas posições devem ficar afastadas da localização do atributo.

**Determinação da dimensionalidade da solução.** A análise de correspondência tenta satisfazer todas essas relações simultaneamente produzindo dimensões que representam

as distâncias qui-quadrado. Para determinar a dimensionalidade da solução, o pesquisador examina o percentual cumulativo de variação explicada, de maneira parecida com o que se faz em análise fatorial, e determina a dimensionalidade adequada. O pesquisador equilibra o desejo por explicação aumentada ao adicionar dimensões extras versus interpretabilidade, pela criação de maior complexidade com cada dimensão somada.

A Tabela 9-11 contém os autovalores e percentuais de variação cumulativa e explicada para cada dimensão até o máximo de sete. Uma solução bidimensional nessa situação explica 86% da variação, ao passo que aumentar para uma solução tridimensional acrescenta apenas 10% à explicação. Ao comparar a variância adicional explicada em relação à complexidade crescente na interpretação dos resultados, uma solução bidimensional é considerada adequada para análise posterior.

### ***Estágio 5: Interpretação dos resultados da CA***

Com o número de dimensões definido, o pesquisador deve prosseguir com uma interpretação do mapa perceptual obtido. Fazendo isso, pelo menos três questões devem ser tratadas: posicionamento de categorias linha e/ou coluna, caracterização das dimensões, e avaliação da adequação de ajuste de categorias individuais. Cada uma delas é discutida nas próximas seções.

**TABELA 9-10** Medidas de similaridade em análise de correspondência: distâncias qui-quadrado

Variáveis	Firma									
	HBAT	A	B	C	D	E	F	G	H	I
$X_6$ Qualidade do produto	-1,02	-1,28	2,37	1,27	1,71	-0,73	-0,83	-1,59	2,99	-1,66
$X_8$ Suporte Técnico	1,24	1,69	-0,01	-2,14	-1,76	0,72	1,32	-1,07	0,10	-0,85
$X_{10}$ Anúncio	0,02	-0,13	0,76	-0,01	0,04	-0,73	0,07	-0,60	1,07	-0,20
$X_{12}$ Imagem da equipe de venda	-1,27	-1,83	-2,08	3,19	1,53	-0,86	-1,73	4,07	-1,42	0,97
$X_{13}$ Preço competitivo	1,08	0,40	-1,10	-1,52	-1,48	0,57	0,59	0,65	-0,36	0,53
$X_{14}$ Garantia e reclamações	-1,32	-1,49	1,15	-1,54	0,23	0,81	0,55	-1,80	-1,44	1,39
$X_{16}$ Encomenda e cobrança	0,19	-0,19	-0,30	0,37	0,42	-0,30	-0,54	0,08	0,20	0,23
$X_{18}$ Velocidade de entrega	0,68	-0,51	-0,95	0,95	-0,27	0,40	0,20	0,86	-1,15	-0,37

**TABELA 9-11** Determinação da dimensionalidade adequada em análise de correspondência

Dimensão	Autovalor (Valor singular)	Inércia (Qui-quadrado normalizado)	Percentual explicado	Percentual cumulativo
1	0,27666	0,07654	53,1	53,1
2	0,21866	0,04781	33,2	86,3
3	0,12366	0,01529	10,6	96,9
4	0,05155	0,00266	1,8	98,8
5	0,02838	0,00081	0,6	99,3
6	0,02400	0,00058	0,4	99,7
7	0,01951	0,00038	0,3	100,0

**Posicionamento relativo de categorias.** A primeira tarefa é avaliar as posições relativas das categorias para as linhas e colunas. Fazendo isso, o pesquisador pode avaliar a associação entre categorias em termos de suas proximidades no mapa perceptual. Note que a comparação deve ser apenas entre categorias na mesma linha ou coluna.

O mapa perceptual mostra as proximidades relativas de empresas e atributos (ver Figura 9-17). Se nos concentrarmos primeiramente nas empresas, perceberemos que o padrão de agrupamentos de firmas é semelhante ao encontrado nos resultados MDS. As empresas A, E, F e I, mais a HBAT, formam um grupo; as empresas C e D e as firmas H e B formam dois outros grupos parecidos. No entanto, as proximidades relativas dos membros em cada grupo diferem um pouco da solução MDS. Além disso, a empresa G é mais isolada e distinta, e as empresas F e E agora são vistas como mais parecidas com a HBAT.

Em termos de atributos, surgem diversos padrões. Primeiro,  $X_6$  e  $X_{13}$ , as duas variáveis negativamente relacionadas, aparecem em extremos opostos do mapa perceptual. Além disso, variáveis exibindo elevada associação (p.ex., formando fatores) também recaem em grande proximidade ( $X_{16}$  e  $X_{18}$ ,  $X_8$  e  $X_{14}$ ). Talvez uma perspectiva mais apropriada seja uma contribuição de atributo a cada dimensão, como se discute a seguir.

**Interpretação das dimensões.** Pode ser útil interpretar as dimensões se normalizações de linhas ou colunas são usadas. Para esses fins, a inércia (variação explicada) de cada dimensão pode ser atribuída entre categorias para linhas e colunas.

A Tabela 9-12 fornece as contribuições de ambos os conjuntos de categorias para cada dimensão. Para os atributos, podemos ver que  $X_{12}$  (Imagem da Equipe de venda) é o principal contribuinte da dimensão I, e  $X_8$  (Suporte Técnico) é um contribuinte secundário. Note que esses dois atributos são extremos em termos de suas localizações na dimensão I (ou seja, valores mais altos ou mais baixos na dimensão I). Entre esses dois atributos, 86%

da dimensão I é explicada. Um padrão semelhante se dá para a dimensão II, para a qual  $X_6$  (Qualidade do Produto) é o principal contribuinte, seguido por  $X_{13}$  (Preço Competitivo), que, quando combinados, explicam 83% da inércia da dimensão II.

Se desviamos nossa atenção para as 10 firmas, perceberemos uma situação um pouco mais equilibrada, em que três firmas (A, C e G) contribuem acima da média de 10%. Para a segunda dimensão, quatro firmas (B, D, G e H) têm contribuições acima da média.

Apesar de as comparações neste exemplo estarem entre ambos os conjuntos de categorias e não restritas a um só conjunto de categorias (linha ou coluna), essas medidas de contribuição demonstram a habilidade para interpretar a dimensão quando assim desejado.


**Avaliação de ajuste para categorias.** Uma medida final fornece uma avaliação de ajuste para cada categoria. Comparáveis com as cargas fatoriais quadradas em análise fatorial (ver Capítulo 3 para uma discussão mais detalhada), esses valores representam a quantia de variação na categoria explicada pela dimensão. Um valor total representa a quantia total de variação ao longo de todas as dimensões, com o máximo possível sendo 100%.

A Tabela 9-12 contém valores de ajuste para cada categoria em cada dimensão. Como podemos ver, os valores de ajuste variam de um valor alto de 99,1 para  $X_6$  (Qualidade do Produto) e  $X_{12}$  (Imagem da Equipe de venda) a um baixo de 0,372 para  $X_{14}$  (Garantia e Reclamações). Entre os atributos, apenas  $X_{14}$  tem um valor abaixo de 50%, e somente duas empresas (HBAT e I) ficam abaixo desse valor. Ainda que esses sejam valores um pouco baixos, eles ainda representam uma explicação suficiente para retê-los na análise e se considerar a mesma com significância prática suficiente.

### Revisão de CA

Essas e outras comparações destacam as diferenças entre os métodos MDS e CA e seus resultados. Os resultados





**FIGURA 9-17** Mapeamento perceptual com métodos composicionais: análise de correspondência.

da CA fornecem um meio para comparar diretamente a similaridade ou dissimilaridade de empresas e os atributos associados, ao passo que o MDS permite apenas a comparação de empresas. Mas a solução CA é condicionada ao conjunto de atributos incluídos. Ela assume que todos os atributos são apropriados para todas as empresas e que a mesma dimensionalidade se aplica a cada empresa. Logo, o mapa perceptual resultante sempre deve ser visto apenas no contexto das empresas e atributos incluídos na análise.

A análise de correspondência é uma técnica bastante flexível aplicável a uma vasta gama de questões e situações. As vantagens do gráfico conjunto de atributos e objetos devem sempre ser ponderadas em relação às interdependências inerentes que existem e aos efeitos potencialmente viesados de um atributo ou empresa inadequados, ou talvez mais importante, do atributo omitido de uma empresa. Não obstante, a CA ainda fornece uma ferramenta poderosa para adquirir visão administrativa sobre a posição relativa de empresas e dos atributos associados com tais posições.

## Estágio 6: Validação dos resultados

Talvez a mais forte validação interna dessa análise seja avaliar a convergência entre os resultados de técnicas decomposicionais e composicionais separadas. Cada técnica emprega diferentes tipos de respostas do consumidor, mas os mapas perceptuais resultantes são representações do mesmo espaço perceptual e devem se corresponder. Se a correspondência é alta, o pesquisador pode estar seguro de que os resultados refletem o problema como descrito. O pesquisador deve observar que esse tipo de convergência não trata da generalidade dos resultados para outros objetos ou amostras da população.

A comparação dos métodos decomposicional e composicional, mostrados nas Figuras 9-12 e 9-17, pode considerar duas abordagens: examinar o posicionamento relativo de objetos e interpretar os eixos. Começamos pelo exame do posicionamento das empresas. Quando as Figuras 9-12 e 9-17 são rotacionadas para obter-se a mes-

(Continua)

TABELA 9-12 Interpretação das dimensões e sua correspondência com firmas e atributos

Objeto	Coordenadas		Contribuição para inércia <sup>a</sup>		Explicação por dimensão <sup>b</sup>		
	I	II	I	II	I	II	Total
<b>Atributo</b>							
$X_6$ Qualidade do produto	0,044	1,235	0,001	0,689	0,002	0,989	0,991
$X_8$ Suporte Técnico	-0,676	-0,285	0,196	0,044	0,789	0,111	0,901
$X_{10}$ Anúncio	-0,081	0,245	0,004	0,045	0,093	0,678	0,772
$X_{12}$ Imagem da equipe de venda	1,506	0,298	0,665	0,033	0,961	0,030	0,991
$X_{13}$ Preço competitivo	-0,202	-0,502	0,018	0,142	0,138	0,677	0,816
$X_{14}$ Garantia e reclamações	-0,440	-0,099	0,087	0,006	0,358	0,014	0,372
$X_{16}$ Encomenda e cobrança	0,115	0,046	0,007	0,001	0,469	0,058	0,527
$X_{18}$ Velocidade de entrega	0,204	-0,245	0,022	0,040	0,289	0,330	0,619
<b>Firma</b>							
HBAT	-0,247	-0,293	0,024	0,042	0,206	0,228	0,433
A	-0,537	-0,271	0,125	0,040	0,772	0,156	0,928
B	-0,444	0,740	0,063	0,224	0,294	0,648	0,942
C	1,017	0,371	0,299	0,050	0,882	0,093	0,975
D	0,510	0,556	0,074	0,111	0,445	0,418	0,863
E	-0,237	-0,235	0,025	0,031	0,456	0,356	0,812
F	-0,441	-0,209	0,080	0,023	0,810	0,144	0,954
G	0,884	-0,511	0,292	0,123	0,762	0,201	0,963
H	-0,206	0,909	0,012	0,289	0,049	0,748	0,797
I	0,123	-0,367	0,006	0,066	0,055	0,390	0,446

<sup>a</sup>Proporção da inércia da dimensão atribuível a cada categoria<sup>b</sup>Proporção de variação de categoria explicada por dimensão

(Continuação)

ma perspectiva, elas exibem padrões bem similares de empresas que refletem dois grupos: empresas B, H, D e C versus E, F, G e I. Embora as distâncias relativas entre empresas variem entre os dois mapas perceptuais, ainda vemos a HBAT fortemente associada às empresas A e I em cada mapa perceptual. A CA produz maior distinção entre as empresas, mas seu objetivo é definir posições de empresas como um resultado de diferenças; logo, ela irá gerar maior distinção em seus mapas perceptuais.

A interpretação de eixos e características de distinção também exhibe padrões semelhantes nos dois mapas perceptuais. Para o método decomposicional exibido na Figura 9-12, notamos na discussão anterior que, pela rotação dos eixos, obteríamos uma interpretação mais clara. Se rotacionamos os eixos, a dimensão I se torna associada com serviço ao cliente e valor do produto ( $X_6$ ,  $X_{13}$ ,  $X_{16}$  e  $X_{18}$ ), ao passo que a dimensão II reflete marketing e suporte técnico ( $X_8$ ,  $X_{10}$  e  $X_{12}$ ). Os demais atributos não são fortemente associados a qualquer eixo.

Para fazer uma comparação com análise de correspondência (Figura 9-17), devemos primeiramente reorientar os eixos. Como podemos ver, as dimensões mudam entre as duas análises. Os agrupamentos de firmas permanecem essencialmente os mesmos, mas estão em posições diferentes no mapa perceptual. Em CA, as dimensões refletem aproximadamente os mesmos ele-

mentos, com as cargas maiores sendo  $X_{18}$  (Velocidade de Entrega) na dimensão I e  $X_{12}$  (Imagem da Equipe de venda) na dimensão II. Isso se compara muito favoravelmente com os resultados decomposicionais, exceto pelo fato de que os outros atributos estão um pouco mais difusos nas dimensões.

No geral, apesar de algumas diferenças de fato existirem devido às características de cada abordagem, a convergência dos dois resultados realmente fornece alguma validade interna aos mapas perceptuais. Diferenças perceptuais podem existir para uns poucos atributos, mas os padrões gerais de posições de empresas e dimensões avaliativas são apoiados por ambas as abordagens. A disparidade do atributo de flexibilidade de preço ilustra as diferenças dos dois métodos.

O pesquisador dispõe de duas ferramentas complementares na compreensão de percepções de clientes. O método decomposicional determina a posição baseado em julgamentos gerais, com os atributos aplicados somente como uma tentativa para explicar as posições. O método composicional posiciona empresas de acordo com o conjunto selecionado de atributos, criando assim posições baseadas nos atributos. Além disso, cada atributo é igualmente ponderado, de modo que há potenciais distorções do mapa com atributos irrelevantes. Essas diferenças não tornam qualquer técnica melhor ou ótima, mas, em vez

disso, devem ser compreendidas pelo pesquisador para garantir a seleção do método mais adequado aos objetivos de pesquisa.

### Uma visão gerencial dos resultados do MDS

O mapeamento perceptual é uma técnica ímpar que fornece comparações gerais que não são prontamente possíveis com qualquer outro método multivariado. Como tal, seus resultados oferecem várias perspectivas para uso administrativo. A aplicação mais comum dos mapas perceptuais é para a avaliação de imagem para qualquer empresa ou grupo de empresas. Enquanto variável estratégica, a imagem pode ser importante como um indicador geral de presença ou posição no mercado.

Neste estudo, descobrimos que a HBAT está mais proximamente associada às empresas A e I e mais distante das empresas C, E e G. Assim, quando servem os mesmos mercados, a HBAT pode identificar as empresas consideradas semelhantes ou distintas de sua imagem. Com os resultados baseados não em qualquer conjunto de atributos específicos, mas em julgamentos gerais de respondentes, as imagens apresentam o benefício de não estarem sujeitas a julgamentos subjetivos de um pesquisador, como atributos a serem incluídos ou a forma de ponderar os atributos individuais, mantendo o verdadeiro espírito de avaliação de imagem. No entanto, as tecnologias MDS são menos úteis para guiar estratégias por serem menos úteis para prescrever como mudar a imagem. As respostas globais que são vantajosas para a comparação agora funcionam contra nós na explicação.

Apesar de as técnicas MDS poderem aumentar a explicação dos mapas perceptuais, elas devem ser vistas como suplementares e provavelmente com maiores inconsistências do que se fossem integradas ao processo. Logo, uma pesquisa adicional pode ajudar a explicar as posições relativas.

Para este fim, os resultados da CA são uma abordagem conciliadora, na tentativa de retratar mapas perceptuais sob uma perspectiva composicional. A comparação de resultados da CA com os da solução MDS clássica revela diversas consistências, mas também algumas discrepâncias.

A comparação das duas soluções identifica alguns padrões gerais de associações entre firmas (como A HBAT e as firmas A e I) e entre grupos de atributos. A administração da HBAT pode usar tais resultados não apenas como um guia para a política geral, mas também como referencial para futura investigação com outras técnicas multivariadas sobre questões de pesquisa mais específicas.

O pesquisador deve observar que nenhuma técnica tem a resposta absoluta, mas que cada uma pode ser usada para capitalizar sobre seus benefícios relativos. Quando empregadas dessa maneira, as diferenças esperadas nas duas técnicas podem, realmente, fornecer visões únicas e complementares sobre a questão de pesquisa.

### Resumo

Escalonamento multidimensional é um conjunto de procedimentos que pode ser usado para representar graficamente as relações descobertas por dados que representam similaridade ou preferência. Essa técnica tem sido usada com sucesso (1) para ilustrar segmentos de mercado com base em julgamentos de preferência, (2) para determinar quais produtos são mais competitivos entre si (isto é, são mais similares), e (3) para deduzir quais critérios as pessoas usam quando julgam objetos (p.ex., produtos, companhias, anúncios). Este capítulo ajuda você a fazer o seguinte:

#### Definir escalonamento multidimensional e descrever como ele é executado.

Escalonamento multidimensional (MDS), também conhecido como mapeamento perceptual, é um procedimento que permite que um pesquisador determine a imagem relativa percebida de um conjunto de objetos (firmas, produtos, idéias ou outros itens associados com percepções comumente mantidas). O propósito do MDS é transformar julgamentos de clientes, quanto a similaridade ou preferência geral (p.ex., preferência por lojas ou marcas), em distâncias representadas em um espaço multidimensional. Para executar uma análise de escalonamento multidimensional, o pesquisador realiza três passos básicos: (1) reúne medidas de similaridade ou de preferência no conjunto inteiro de objetos a serem analisados, (2) usa técnicas MDS para estimar a posição relativa de cada objeto no espaço multidimensional, e (3) identifica e interpreta os eixos do espaço dimensional em termos de atributos perceptuais e/ou objetivos. O mapa perceptual, também chamado de mapa espacial, exibe o posicionamento relativo de todos os objetos.

#### Entender as diferenças entre dados de similaridade e de preferência.

Depois de escolher objetos para o estudo, o pesquisador deve a seguir escolher a base de avaliação: similaridade ou preferência. Ao fornecerem dados de similaridade, os respondentes não aplicam quaisquer aspectos do tipo “bom-ruim” de avaliação na comparação, mas com dados de preferência avaliações desse tipo são feitas. Em resumo, dados de preferência assumem que diferentes combinações de atributos percebidos são melhor valoradas do que outras. Ambas as bases de comparação podem ser usadas para desenvolver mapas perceptuais, mas com diferentes interpretações: (1) mapas perceptuais baseados em similaridade representam semelhanças de atributos e dimensões perceptuais de comparação, mas não refletem

qualquer visão direta sobre os determinantes de escolha; e (2) mapas perceptuais baseados em preferências refletem escolhas preferidas, mas podem não corresponder de forma alguma às posições baseadas em semelhança, pois respondentes podem sustentar suas escolhas sobre dimensões ou critérios inteiramente diferentes daqueles nos quais eles baseiam comparações. Sem qualquer base ótima para avaliação, a decisão entre dados de similaridades e de preferência deve ser feita com a mais importante questão de pesquisa em mente, pois eles são fundamentalmente distintos em termos do que representam.

**Selecionar entre uma abordagem decomposicional e uma composicional.** Técnicas de mapeamento perceptual podem ser classificadas em um entre dois tipos, com base na natureza das respostas obtidas a partir de indivíduos, referentes a objetos: (1) o método decomposicional, que mede somente a impressão ou avaliação geral de um objeto e então tenta derivar posições espaciais em espaço multidimensional que reflitam essas percepções (ele emprega dados de similaridade ou de preferência e é a abordagem tipicamente associada ao MDS), e (2) o método composicional, que emprega diversas técnicas multivariadas já discutidas que são usadas para formar uma impressão ou avaliação com base em uma combinação de atributos específicos. Mapeamentos perceptuais podem ser realizados com técnicas tanto decompositivas quanto composicionais, mas cada técnica apresenta vantagens e desvantagens específicas que devem ser consideradas do ponto de vista dos objetivos da pesquisa. Se o mapeamento perceptual é levado a cabo como técnica exploratória para identificar dimensões não-reconhecidas ou como meio de se obter avaliações comparativas de objetos quando as bases específicas de comparação são desconhecidas ou não-definidas, as abordagens decompositivas (livres de atributos) são as mais adequadas. Em contrapartida, se as metas da pesquisa incluem a representação gráfica entre objetos em um conjunto definido de atributos, então as técnicas composicionais são a alternativa preferível.

**Determinar a comparabilidade e o número de objetos.** Antes de se executar qualquer estudo de mapeamento perceptual, o pesquisador deve tratar de duas questões-chave em relação aos objetos sendo avaliados. Essas questões lidam com a garantia de comparabilidade dos objetos e com a seleção do número de objetos a serem avaliados. A primeira questão ao se selecionar objetos é: eles são realmente comparáveis? Uma suposição implícita em mapeamento perceptual é aquela sobre características em comum, sejam objetivas ou percebidas, usadas pelo respondente no processo de avaliação. Logo, é essencial que os objetos sob comparação tenham um conjunto de atributos inerentes que caracterizam cada um deles e formam a base de comparação feita pelo respondente. Não é possível que o pesquisador force o respondente a fazer comparações criando pares de ob-

jetos não comparáveis. Uma segunda questão se refere ao número de objetos a serem avaliados. Ao se decidir quantos objetos devem ser incluídos, o pesquisador deve equilibrar dois desejos: por um número menor de objetos para facilitar o esforço por parte do respondente, e por uma quantia exigida de objetos para se obter uma solução multidimensional estável. Geralmente deve ser feita uma negociação entre o número de dimensões inerentes que podem ser identificadas e o esforço exigido por parte do respondente para avaliá-las.

**Entender como criar um mapa perceptual.** Três passos estão envolvidos na criação de um mapa perceptual com base nas posições ótimas dos objetos. O primeiro é escolher uma configuração inicial de estímulos em uma dimensionalidade inicial desejada. As duas abordagens mais amplamente utilizadas para obter a configuração inicial são aquela que se sustenta em dados prévios e aquela que gera uma através da seleção de pontos pseudo-aleatórios a partir de uma distribuição multivariada aproximadamente normal. O segundo passo é computar as distâncias entre os pontos de estímulos e comparar as relações (observadas versus derivadas) com uma medida de ajuste. Uma vez que a configuração é encontrada, as distâncias entre estímulos nas configurações iniciais são comparadas com as medidas de distância obtidas a partir de julgamentos de similaridade. As duas medidas de distância são então comparadas por uma medida de ajuste, geralmente sendo uma medida de desajuste. O terceiro passo é necessário se a medida de ajuste não alcançar um valor de parada previamente escolhido. Em tais casos, você encontra uma nova configuração para a qual a medida de ajuste é minimizada. O programa de computador determina as direções nas quais o melhor ajuste pode ser obtido e então move os pontos na configuração naquelas direções em pequenos incrementos.

**Explicar análise de correspondência como um método de mapeamento perceptual.** Análise de correspondência (CA) é uma técnica de interdependência que tem se tornado cada vez mais popular para redução dimensional e mapeamento perceptual. A análise de correspondência tem três características marcantes: (1) é uma técnica composicional, e não decomposicional, porque o mapa perceptual se baseia na associação entre objetos e um conjunto de características ou atributos descritivos especificados pelo pesquisador; (2) é a aplicação mais direta na representação gráfica da correspondência de categorias de variáveis, particularmente aquelas medidas em escalas nominais, que é então usada como a base para o desenvolvimento de mapas perceptuais; e (3) os benefícios exclusivos da CA repousam em suas habilidades para representar linhas e colunas, por exemplo, marcas e atributos, em um espaço conjunto. Resumidamente, a análise de correspondência oferece uma valiosa ferramenta analítica para um tipo de dado (não-métrico) que frequentemente



não é o ponto focal de técnicas multivariadas. A análise de correspondência também oferece ao pesquisador uma técnica composicional complementar a MDS para tratar de questões nas quais a comparação direta de objetos e atributos é preferível.

O MDS pode revelar relações que parecem estar obscuras quando se examinam somente os números resultantes de um estudo. Um mapa perceptual com apelo visual enfatiza as relações entre os estímulos sob estudo. Devemos tomar muito cuidado quando utilizamos essa técnica. O seu uso de forma incorreta é comum. O pesquisador deve se familiarizar com o método antes de usá-lo e ver os resultados apenas como o primeiro passo para a determinação de informações perceptuais.

### Questões

1. Como o MDS difere de outras técnicas de interdependência (análise de agrupamentos e análise fatorial)?
2. Qual é a diferença entre dados de preferência e dados de similaridade, e que impacto eles têm sobre os resultados de procedimentos MDS?
3. Como os pontos ideais são empregados em procedimentos MDS?
4. Quais são as diferenças entre procedimentos MDS métricos e não-métricos?
5. Como o pesquisador pode determinar quando a solução MDS ótima foi obtida?
6. Como o pesquisador identifica as dimensões em MDS? Compare esse método com o procedimento para a análise fatorial.
7. Compare e contraste as técnicas CA e MDS.
8. Descreva como é obtida correspondência ou associação a partir de uma tabela de contingência.
9. Descreva os métodos para interpretação de categorias (linha ou coluna) em CA. As categorias sempre podem ser diretamente comparadas com base em proximidade no mapa perceptual?

### Leituras sugeridas

Uma lista de leituras sugeridas que ilustram problemas e aplicações de técnicas multivariadas em geral está disponível na Web em [www.prenhall.com/hair](http://www.prenhall.com/hair) (em inglês).

### Referências

1. Carroll, J. Douglas, Paul E. Green, and Catherine M.-Schaffer. 1986. Interpoint Distance Comparisons in Correspondence Analysis. *Journal of Marketing Research* 23 (August): 271–80.
2. Carroll, J. Douglas, Paul E. Green, and Catherine M.-Schaffer. 1987. Comparing Interpoint Distances in Correspondence Analysis: A Clarification. *Journal of Marketing Research* 24 (November): 445–50.
3. Chang, J. J., and J. Douglas Carroll. 1968. How to Use PROFIT, a Computer Program for Property Fitting-by Optimizing Nonlinear and Linear Correlation. Unpublished paper, Bell Laboratories, Murray Hill, NJ.
4. Chang, J. J., and J. Douglas Carroll. 1969. How to Use INDSCAL, a Computer Program for Canonical Decomposition of  $n$ -Way Tables and Individual Differences in Multidimensional Scaling. Unpublished paper, Bell Laboratories, Murray Hill, NJ.
5. Chang, J. J., and J. Douglas Carroll. 1969. How to Use MDPREF, a Computer Program for Multidimensional Analysis of Preference Data. Unpublished paper, Bell Laboratories, Murray Hill, NJ.
6. Chang, J. J., and J. Douglas Carroll. 1972. How to Use PREFMAP and PREFMAP2—Programs Which Relate Preference Data to Multidimensional Scaling Solution. Unpublished paper, Bell Laboratories, Murray Hill, NJ.
7. Green, P. E. 1975. On the Robustness of Multidimensional Scaling Techniques. *Journal of Marketing Research* 12 (February): 73–81.
8. Green, P. E., and F. Carmone. 1969. Multidimensional Scaling: An Introduction and Comparison of Nonmetric Unfolding Techniques. *Journal of Marketing Research* 7 (August): 33–41.
9. Green, P. E., F. Carmone, and Scott M. Smith. 1989. *Multidimensional Scaling: Concept and Applications*. Boston: Allyn & Bacon.
10. Green, P. E., and Vithala Rao. 1972. *Applied Multidimensional Scaling*. New York: Holt, Rinehart and Winston.
11. Greenacre, Michael J. 1984. *Theory and Applications of Correspondence Analyses*. London: Academic Press.
12. Greenacre, Michael J. 1989. The Carroll-Green-Schaffer Scaling in Correspondence Analysis: A-Theoretical and Empirical Appraisal. *Journal of Marketing Research* 26 (August): 358–65.
13. Hoffman, Donna L., and George R. Franke. 1986. Correspondence Analysis: Graphical Representation of Categorical Data in Marketing Research. *Journal of Marketing Research* 23 (August): 213–27.
14. Holbrook, Morris B., William L. Moore, and Russell S. Winer. 1982. Constructing Joint Spaces from Pick-Any Data: A New Tool for Consumer Analysis. *Journal of Consumer Research* 9 (June): 99–105.
15. Levine, Joel H. 1979. Joint-Space Analysis of “Pick-Any” Data: Analysis of Choices from an Unconstrained Set of Alternatives. *Psychometrika* 44 (March): 85–92.
16. Lingoes, James C. 1972. *Geometric Representations of Relational Data*. Ann Arbor, MI: Mathesis Press.
17. Kruskal, Joseph B., and Frank J. Carmone. 1967. How to Use MDSCAL. Version 5-M, and Other Useful Information. Unpublished paper, Bell Laboratories, Murray Hill, NJ.
18. Kruskal, Joseph B., and Myron Wish. 1978. *Multidimensional Scaling*. Sage University Paper Series on Quantitative Applications in the Social Sciences, 07–011, Beverly Hills, CA: Sage.
19. Lebart, Ludovic, Alain Morineau, and Kenneth M.-Warwick. 1984. *Multivariate Descriptive Statistical-Analysis: Correspondence Analysis and-Related Techniques for Large Matrices*. New York: Wiley.



20. Maholtra, Naresh. 1987. Validity and Structural Reliability of Multidimensional Scaling. *Journal of Marketing Research* 24 (May): 164–73.
21. Market ACTION Research Software, Inc. 1989. *MAPWISE: Perceptual Mapping Software*. Peoria, IL: Business Technology Center, Bradley-University.
22. Raymond, Charles. 1974. *The Art of Using Science in Marketing*. New York: Harper & Row.
23. Schiffman, Susan S., M. Lance Reynolds, and Forrest W. Young. 1981. *Introduction to Multidimensional Scaling*. New York: Academic Press.
24. Smith, Scott M. 1989. *PC-MDS: A Multidimensional Statistics Package*. Provo, UT: Brigham Young University.
25. Srinivasan, V., and A. D. Schocker. 1973. Linear Programming Techniques for Multidimensional Analysis of Preferences. *Psychometrika* 38 (September): 337–69.